

# Contrôle continu de statistiques

L1 Biotechnologies S1 – 2025-2026

Nom :

Prénom :

Groupe :

vendredi 5 déc. 2025

## Instructions importantes

**Durée : 1 heure | Barème : 20 points**

**Tous les documents sont autorisés, mais l'utilisation des IA génératives est interdite**

- Le fichier de données **enzyme.txt** est disponible en ligne et on vous
- Répondez directement sur ce sujet en mobilisant le codes
- **Écrivez uniquement les résultats numériques et vos interprétations** (pas besoin de recopier le code, **sauf mention contraire**)
- Arrondissez vos résultats à 2 décimales sauf indication contraire

## Contexte de l'étude

Vous analysez des données d'une expérience portant sur **l'activité enzymatique de souches bactériennes différentes à différents pH**. Le jeu de données contient **80 observations** avec les variables suivantes :

- **echantillon** : l'identifiant de l'échantillon sous la forme **eX** avec **X** le numéro de l'échantillon,
- **souche** : le nom de la souche étudiée (**souche\_a**, **souche\_b**, **souche\_c** ou bien **souche\_d**)
- **activite\_ph6** : l'activité de la souche bactérienne avec quand le pH du milieu vaut 6
- **activite\_ph7** : l'activité de la souche bactérienne avec quand le pH du milieu vaut 7

## Partie 1 : Statistiques Descriptives {13 points}

### Question 1 : Exploration initiale (2 points)

Après avoir chargé les données, répondez aux questions suivantes :

a) Combien y a-t-il de lignes et de colonnes dans le jeu de données ?

Réponse : \_\_\_\_\_ lignes et \_\_\_\_\_ colonnes

b) Combien de niveaux différents compte la variable **souche** ?

Réponse : \_\_\_\_\_ niveaux

### Question 2 : Statistiques univariées (3 points)

Pour la variable **activité enzymatique à pH 6** (`activite_ph6`), calculez les statistiques suivantes :

Moyenne : \_\_\_\_\_ Médiane : \_\_\_\_\_ Écart-type : \_\_\_\_\_

Q1 (25%) : \_\_\_\_\_ Q3 (75%) : \_\_\_\_\_

Minimum : \_\_\_\_\_ Maximum : \_\_\_\_\_

### Question 3 : Statistiques par groupe (3 points)

Calculez la moyenne et l'écart-type de **activite\_ph6** pour la première **souche bactérienne** (`=souche_a`) :

Moyenne :

Écart-type :

### Question 4 : Graphiques de distribution (5 points)

a) Créez un **histogramme** de **activite\_ph6** et décrivez la forme de la distribution (symétrique, asymétrique à gauche/droite, bimodale...).

**b)** Créez un **boxplot** de **activite\_ph6** par **souche**. Quel groupe présente la plus grande étendue ?  
(Vous pouvez utiliser l'instruction sous la forme suivante `boxplot(data$variable_quantitative ~ data$variable_categorielle)` pour représenter les boxplots côte-à-côte)

Groupe avec la plus grande étendue : \_\_\_\_\_

Justification : \_\_\_\_\_

## **Partie 2 : Statistiques Inférentielles {7 points}**

**Question 5** : Intervalle de confiance (3 points)

Calculez un **intervalle de confiance à 95%** pour la moyenne de **activite\_ph6**.

**a)** L'intervalle de confiance à 95% est : [ \_\_\_\_\_ ; \_\_\_\_\_ ] U/mL

**b)** Si vous calculiez un IC à 99% au lieu de 95%, serait-il plus large ou plus étroit ?

Réponse : \_\_\_\_\_

Pourquoi ? \_\_\_\_\_

**Question 6** : Test de Student (4 points)

Comparez **activite\_ph6** des deux groupes **souche\_a** et **souche\_d**

**a)** Hypothèses :

$H_0$  : \_\_\_\_\_

$H_1$  : \_\_\_\_\_

**b)** Vérification des conditions d'applications :

**c)** *p-value* :  $p =$  \_\_\_\_\_

**d)** Conclusion au seuil  $\alpha = 0.05$  :

## Questions Bonus

### Note

Ces questions ne sont pas comptées dans le total de 20 points et peuvent vous permettre d'obtenir jusqu'à deux points supplémentaires !

### Question Bonus 1 (1 point)

Pourquoi la médiane est-elle préférable à la moyenne comme indicateur de position pour des données très asymétriques ?

### Question Bonus 2 (1 point)

Donnez une estimation de la note (entre 0 et 20) que vous allez obtenir à ce contrôle continu, sans compter les points bonus.