

Contrôle continu de statistiques

L1 Biotechnologies S1 – 2025-2026

Nom :

Prénom :

Groupe :

vendredi 5 déc. 2025

Instructions importantes

Durée : 1 heure | Barème : 20 points

Tous les documents sont autorisés, mais l'utilisation des IA génératives est interdite

- Le fichier de données `fermentation.txt` est disponible en ligne et on vous
- Répondez directement sur ce sujet en mobilisant le codes
- **Écrivez uniquement les résultats numériques et vos interprétations** (pas besoin de recopier le code, **sauf mention contraire**)
- Arrondissez vos résultats à 2 décimales sauf indication contraire

Contexte de l'étude

Vous analysez des données d'une expérience portant sur **la production d'éthanol de différentes espèces de levures en conditions contrôlées**. Le jeu de données contient **72 observations** avec les variables suivantes :

- `echantillon` : l'identifiant de l'échantillon sous la forme `fX` avec `X` le numéro de l'échantillon
- `levure` : le nom d'espèce de la levure utilisée (`K_marxianus` = *Kluyveromyces marxianus*, `K_pastoris` = *Komagataella pastoris*, `S_bayanus` = *Saccharomyces bayanus*, `S_cerevisiae` = *Saccharomyces cerevisiae*)
- `ethanol_anaerobie` : la concentration en éthanol (en $\text{g}\cdot\text{L}^{-1}$) final en conditions anéarobies
- `ethanol_aerobie` : la concentration en éthanol (en $\text{g}\cdot\text{L}^{-1}$) final en conditions aérobies
- `temperature` : la température utilisée dans l'expérience
- `sucre_initial` : la quantité de sucre présente au début de l'expérience

Partie 1 : Statistiques Descriptives {13 points}

Question 1 : Exploration initiale (2 points)

Après avoir chargé les données, répondez aux questions suivantes :

a) Combien y a-t-il de lignes et de colonnes dans le jeu de données ?

Réponse : _____ lignes et _____ colonnes

b) Combien de niveaux différents compte la variable **levure** ?

Réponse : _____ niveaux

Question 2 : Statistiques univariées (3 points)

Pour la variable **production d'éthanol (anaérobie)** (`ethanol_anaerobie`), calculez les statistiques suivantes :

Moyenne : _____ Médiane : _____ Écart-type : _____

Q1 (25%) : _____ Q3 (75%) : _____

Minimum : _____ Maximum : _____

Question 3 : Statistiques par groupe (3 points)

Calculez la moyenne et l'écart-type de **ethanol_anaerobie** pour la première **souche de levure** (`S_bayanus`) :

Moyenne :

Écart-type :

Question 4 : Graphiques de distribution (5 points)

a) Créez un **histogramme** de **ethanol_anaerobie** et décrivez la forme de la distribution (symétrique, asymétrique à gauche/droite, bimodale...).

b) Créez un **boxplot** de **ethanol_anaerobie** par **levure**. Quel groupe présente la plus grande étendue ?

(Vous pouvez utiliser l'instruction sous la forme suivante `boxplot(data$variable_quantitative ~ data$variable_categorielle)` pour représenter les boxplots côte-à-côte)

Groupe avec la plus grande étendue : _____

Justification : _____

Partie 2 : Statistiques Inférentielles {7 points}

Question 5 : Intervalle de confiance (3 points)

Calculez un **intervalle de confiance à 95%** pour la moyenne de **ethanol_anaerobie**.

a) L'intervalle de confiance à 95% est : [_____ ; _____] g/L

b) Si vous calculiez un IC à 99% au lieu de 95%, serait-il plus large ou plus étroit ?

Réponse : _____

Pourquoi ? _____

Question 6 : Test de Student (4 points)

Comparez **ethanol_anaerobie** des deux groupes **K_pastoris** et **S_cerevisiae**

a) Hypothèses :

H_0 : _____

H_1 : _____

b) Vérification des conditions d'applications :

c) *p-value* : $p =$ _____

d) Conclusion au seuil $\alpha = 0.05$:

Questions Bonus

Note

Ces questions ne sont pas comptées dans le total de 20 points et peuvent vous permettre d'obtenir jusqu'à deux points supplémentaires !

Question Bonus 1 (1 point)

Pourquoi la médiane est-elle préférable à la moyenne comme indicateur de position pour des données très asymétriques ?

Question Bonus 2 (1 point)

Donnez une estimation de la note (entre 0 et 20) que vous allez obtenir à ce contrôle continu, sans compter les points bonus.