

Contrôle continu de statistiques

L1 Biotechnologies S1 – 2025-2026

Nom :

Prénom :

Groupe :

vendredi 5 déc. 2025

Instructions importantes

Durée : 1 heure | Barème : 20 points

Tous les documents sont autorisés, mais l'utilisation des IA génératives est interdite

- Le fichier de données `fermentation.txt` est disponible en ligne et on vous
- Répondez directement sur ce sujet en mobilisant le codes
- **Écrivez uniquement les résultats numériques et vos interprétations** (pas besoin de recopier le code, **sauf mention contraire**)
- Arrondissez vos résultats à 2 décimales sauf indication contraire

Contexte de l'étude

Vous analysez des données d'une expérience portant sur **la production d'éthanol de différentes espèces de levures en conditions contrôlées**. Le jeu de données contient **72 observations** avec les variables suivantes :

- `echantillon` : l'identifiant de l'échantillon sous la forme `fX` avec `X` le numéro de l'échantillon
- `levure` : le nom d'espèce de la levure utilisée (`K_marxianus` = *Kluyveromyces marxianus*, `K_pastoris` = *Komagataella pastoris*, `S_bayanus` = *Saccharomyces bayanus*, `S_cerevisiae` = *Saccharomyces cerevisiae*)
- `ethanol_anaerobie` : la concentration en éthanol (en $\text{g}\cdot\text{L}^{-1}$) final en conditions anéarobies
- `ethanol_aerobie` : la concentration en éthanol (en $\text{g}\cdot\text{L}^{-1}$) final en conditions aérobies
- `temperature` : la température utilisée dans l'expérience
- `sucre_initial` : la quantité de sucre présente au début de l'expérience

Partie 1 : Statistiques Descriptives {13 points}

Question 1 : Exploration initiale (2 points)

Après avoir chargé les données, répondez aux questions suivantes :

a) Combien y a-t-il de lignes et de colonnes dans le jeu de données ?

Réponse : 72 lignes et 6 colonnes

b) Combien de niveaux différents compte la variable **levure** ?

Réponse : 4 niveaux

Question 2 : Statistiques univariées (3 points)

Pour la variable **production d'éthanol (anaérobie)** (`ethanol_anaerobie`), calculez les statistiques suivantes :

Moyenne : 9.3397222 Médiane : 9.175 Écart-type : 2.8619721

Q1 (25%) : 8.0525 Q3 (75%) : 10.4925

Minimum : 2 Maximum : 19.09

Question 3 : Statistiques par groupe (3 points)

Calculez la moyenne et l'écart-type de **ethanol_anaerobie** pour la première **souche de levure** (`S_bayanus`) :


Moyenne : 9.4736842

Écart-type : 2.2237611

Question 4 : Graphiques de distribution (5 points)

a) Créez un **histogramme** de **ethanol_anaerobie** et décrivez la forme de la distribution (symétrique, asymétrique à gauche/droite, bimodale...).


Histogram of enzyme[[var_principale]]



b) Créez un **boxplot** de **ethanol_anaerobie** par **levure**. Quel groupe présente la plus grande étendue ?

(Vous pouvez utiliser l'instruction sous la forme suivante `boxplot(data$variable_quantitative ~ data$variable_categorielle)` pour représenter les boxplots côte-à-côte)

```
boxplot(ethanol_anaerobie ~ levure, data = enzyme)
```



Groupe avec la plus grande étendue : K_marxianus

Justification : moustaches plus larges (écart minimum-maximum)

Partie 2 : Statistiques Inférentielles {7 points}

Question 5 : Intervalle de confiance (3 points)

Calculez un **intervalle de confiance à 95%** pour la moyenne de **ethanol_anaerobie**.

```
t.test(data[[var_principale]])$conf.int
```

```
[1] 8.667192 10.012253  
attr(,"conf.level")  
[1] 0.95
```

a) L'intervalle de confiance à 95% est : **[8,66 ; 10,02]** g/L

b) Si vous calculiez un IC à 99% au lieu de 95%, serait-il plus large ou plus étroit ?

Réponse : Plus large

Pourquoi ? Un niveau de confiance plus élevé nécessite d'avoir un intervalle plus large

Question 6 : Test de Student (4 points)

Comparez **ethanol_anaerobie** des deux groupes **K_pastoris** et **S_cerevisiae**

a) Hypothèses :

H_0 : Les deux levures produisent la même quantité d'éthanol en anéaérobie

H_1 : Les deux levures produisent des quantités d'éthanol différentes en anéaérobie

b) Vérification des conditions d'applications :

Il faut d'abord regarder la longueur des échantillons

K_marxianus	K_pastoris	S_bayanus	S_cerevisiae
22	19	19	12

On a moins de 30 observations dans les deux groupes, il faut donc vérifier la normalité des deux échantillons et l'égalité de leurs variances.

Normalité : test de Shapiro-Wilk

Hypothèses : H_0 : l'échantillon suit une loi normale H_1 : l'échantillon ne suit pas une loi normale

Shapiro-Wilk normality test

```
data: data[data[[var_categorielle]] == "K_pastoris", var_principale]
W = 0.91764, p-value = 0.1024
```

Shapiro-Wilk normality test

```
data: data[data[[var_categorielle]] == "S_cerevisiae", var_principale]
W = 0.87848, p-value = 0.08381
```

Dans les deux cas, on observe $p > 0.05$, donc on accepte H_0 , ce qui signifie qu'ils suivent tous les deux une loi normale.

Égalité des variances : test de Fisher

Hypothèses :

H_0 : Les variances des deux échantillons sont égales H_1 : Les variances des deux échantillons sont différentes

F test to compare two variances

```
data: data[data[[var_categorielle]] == "K_pastoris", var_principale] and data[data[[var_categorielle]] == "S_cerevisiae", var_principale]
F = 1.0601, num df = 18, denom df = 11, p-value = 0.9508
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.3250651 2.9828744
sample estimates:
ratio of variances
      1.060113
```

On observe $p = 0.38 \gg 0.05$, donc on ne rejette pas H_0 , et donc les variances des deux échantillons sont égales. Donc on peut procéder au test de Student

Two Sample t-test

```
data: data[data[[var_categorielle]] == "K_pastoris", var_principale] and data[data[[var_categorielle]] == "K_martii", var_principale]
t = 0.19547, df = 29, p-value = 0.8464
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.9006577  1.0910086
sample estimates:
mean of x mean of y
 9.026842  8.931667
```

c) *p-value* : $p = 0.85$

d) Conclusion au seuil $\alpha = 0.05$:

On observe $p = 0.85 \gg \alpha = 0.05$, donc on ne rejette pas H_0 , ce qui signifie que les deux levures produisent la même concentration d'éthanol en conditions anaérobies

Questions Bonus

Note

Ces questions ne sont pas comptées dans le total de 20 points et peuvent vous permettre d'obtenir jusqu'à deux points supplémentaires !

Question Bonus 1 (1 point)

Pourquoi la médiane est-elle préférable à la moyenne comme indicateur de position pour des données très asymétriques ?

Question Bonus 2 (1 point)

Donnez une estimation de la note (entre 0 et 20) que vous allez obtenir à ce contrôle continu, sans compter les points bonus.