

Contrôle continu de statistiques

L1 Biotechnologies S1 – 2025-2026

Nom :

Prénom :

Groupe :

vendredi 5 déc. 2025

Instructions importantes

Durée : 1 heure | Barème : 20 points

Tous les documents sont autorisés, mais l'utilisation des IA génératives est interdite

- Le fichier de données **enzyme.txt** est disponible en ligne et on vous
- Répondez directement sur ce sujet en mobilisant le codes
- **Écrivez uniquement les résultats numériques et vos interprétations** (pas besoin de recopier le code, **sauf mention contraire**)
- Arrondissez vos résultats à 2 décimales sauf indication contraire

Contexte de l'étude

Vous analysez des données d'une expérience portant sur **l'activité enzymatique de souches bactériennes différentes à différents pH**. Le jeu de données contient **80 observations** avec les variables suivantes :

```
a = ""
if (params$experience_type == "enzyme") {
  a = "
  - `echantillon` : l'identifiant de l'échantillon sous la forme `eX` avec `X` le numéro d
  - `souche` : le nom de la souche étudiée (`souche_a`, `souche_b`, `souche_c` ou bien `so
  - `activite_ph6` : l'activité de la souche bactérienne avec quand le pH du milieu vaut 6
  - `activite_ph7` : l'activité de la souche bactérienne avec quand le pH du milieu vaut 7
  "
} else if (params$experience_type == "fermentation") {

  a = "
  - `echantillon` : l'identifiant de l'échantillon sous la forme `fX` avec `X` le numéro
  - `levure` : le nom d'espèce de la levure utilisée (`K_marxianus` = _Kluyveromyces marx
  - `ethanol_anaerobie` : la concentration en éthanol (en g·L-1) final en conditions anéa
```

```

- `ethanol_aerobie` : la concentration en éthanol (en g·L-1) final en conditions aérobie
- `temperature` : la température utilisée dans l'expérience
- `sucre_initial` : la quantité de sucre présente au début de l'expérience
"
}

knitr::asis_output(a)

```

- `echantillon` : l'identifiant de l'échantillon sous la forme `eX` avec `X` le numéro de l'échantillon,
- `souche` : le nom de la souche étudiée (`souche_a`, `souche_b`, `souche_c` ou bien `souche_d`)
- `activite_ph6` : l'activité de la souche bactérienne avec quand le pH du milieu vaut 6
- `activite_ph7` : l'activité de la souche bactérienne avec quand le pH du milieu vaut 7

Partie 1 : Statistiques Descriptives {13 points}

Question 1 : Exploration initiale (2 points)

Après avoir chargé les données, répondez aux questions suivantes :

a) Combien y a-t-il de lignes et de colonnes dans le jeu de données ?

Réponse : 80 lignes et 4 colonnes

b) Combien de niveaux différents compte la variable **souche** ?

Réponse : 4 niveaux

Question 2 : Statistiques univariées (3 points)

Pour la variable **activité enzymatique à pH 6** (`activite_ph6`), calculez les statistiques suivantes :

Moyenne : 46.239875 Médiane : 47.12 Écart-type : 9.9876298

Q1 (25%) : 39.67 Q3 (75%) : 53.17

Minimum : 18.41 Maximum : 75.65

Question 3 : Statistiques par groupe (3 points)


Calculez la moyenne et l'écart-type de **activite_ph6** pour la première **souche bactérienne** (`=souche_a`) :

Moyenne : 46.0226087

Écart-type : 13.6793378


Question 4 : Graphiques de distribution (5 points)

a) Créez un **histogramme** de **activite_ph6** et décrivez la forme de la distribution (symétrique, asymétrique à gauche/droite, bimodale...).



b) Créez un **boxplot** de **activite_ph6** par **souche**. Quel groupe présente la plus grande étendue ?
 (Vous pouvez utiliser l'instruction sous la forme suivante `boxplot(data$variable_quantitative ~ data$variable_categorielle)` pour représenter les boxplots côte-à-côte)

```
boxplot(activite_ph6 ~ souche, data = enzyme)
```



Groupe avec la plus grande étendue : souche_a

Justification : moustaches plus larges (écart minimum-maximum)

Partie 2 : Statistiques Inférentielles {7 points}

Question 5 : Intervalle de confiance (3 points)

Calculez un **intervalle de confiance à 95%** pour la moyenne de **activite_ph6**.

```
t.test(data[[var_principale]])$conf.int
```

```
[1] 44.01724 48.46251  
attr(,"conf.level")  
[1] 0.95
```

a) L'intervalle de confiance à 95% est : **[44.01 ; 48.47]** U/mL

b) Si vous calculiez un IC à 99% au lieu de 95%, serait-il plus large ou plus étroit ?

Réponse : Plus large

Pourquoi ? Un niveau de confiance plus élevé nécessite d'avoir un intervalle plus large

Question 6 : Test de Student (4 points)

Comparez **activite_ph6** des deux groupes **souche_a** et **souche_d**

a) Hypothèses :

H_0 : Les deux souches bactériennes présentent la même activité à pH 6

H_1 : Les deux souches bactériennes ont des activités différentes à pH 6

b) Vérification des conditions d'applications :

Il faut d'abord regarder la longueur des échantillons

souche_a	souche_b	souche_c	souche_d
23	20	18	19

On a moins de 30 observations dans les deux groupes, il faut donc vérifier la normalité des deux échantillons et l'égalité de leurs variances.

Normalité : test de Shapiro-Wilk

Hypothèses : H_0 : l'échantillon suit une loi normale H_1 : l'échantillon ne suit pas une loi normale

Shapiro-Wilk normality test

```
data: data[data[[var_categorielle]] == "souche_a", var_principale]
W = 0.98793, p-value = 0.9905
```

Shapiro-Wilk normality test

```
data: data[data[[var_categorielle]] == "souche_d", var_principale]
W = 0.90648, p-value = 0.06383
```

Dans les deux cas, on observe $p > 0.05$, donc on accepte H_0 , ce qui signifie qu'ils suivent tous les deux une loi normale.

Égalité des variances : test de Fisher

Hypothèses :

H_0 : Les variances des deux échantillons sont égales H_1 : Les variances des deux échantillons sont différentes

F test to compare two variances

```
data: data[data[[var_categorielle]] == "souche_a", var_principale] and data[data[[var_cat
F = 1.5141, num df = 22, denom df = 18, p-value = 0.3751
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.5988113 3.6735516
sample estimates:
ratio of variances
      1.514101
```

On observe $p = 0.38 \gg 0.05$, donc on ne rejette pas H_0 , et donc les variances des deux échantillons sont égales. Donc on peut procéder au test de Student

Two Sample t-test

```
data: data[data[[var_categorielle]] == "souche_a", var_principale] and data[data[[var_cat
t = 0.13631, df = 40, p-value = 0.8923
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -7.356992  8.421156
sample estimates:
mean of x mean of y
 46.02261  45.49053
```

c) *p-value* : $p = 0.89$

d) Conclusion au seuil $\alpha = 0.05$:

On observe $p = 0.89 \gg \alpha = 0.05$, donc on ne rejette pas H_0 , ce qui signifie que les deux souches ont les mêmes activités à pH 6.

Questions Bonus

Note

Ces questions ne sont pas comptées dans le total de 20 points et peuvent vous permettre d'obtenir jusqu'à deux points supplémentaires !

Question Bonus 1 (1 point)

Pourquoi la médiane est-elle préférable à la moyenne comme indicateur de position pour des données très asymétriques ?

Question Bonus 2 (1 point)

Donnez une estimation de la note (entre 0 et 20) que vous allez obtenir à ce contrôle continu, sans compter les points bonus.