



Jardin à Bonnières par Georgette AGUTTE
XXe siècle, [Musée de Grenoble](#), Domaine Public
Crédits photographiques : Ville de Grenoble /
Musée de Grenoble-J.L. Lacroix

Statistiques Descriptives et Inférentielles 1


MCIA1U02
Proba. & Stats. Pour l'analyse de données
L1 IA & Santé S1 – 2026-2027
Matthias Grenié
(matthias.grenie@univ-grenoble-alpes.fr)

Qui suis-je ?

Présentation



Écologue spécialiste de la biodiversité à large échelle




Quels facteurs expliquent la répartition actuelle de la biodiversité ?

Sujet de recherche : L'écologie des plantes médicinales


Nombre d'espèces de plantes médicinales en Europe
(Leaman et al. 2014)



Demande accrue en produit issus
de plantes médicinales
(phytothérapie, aromathérapie)
Majorité de ces plantes **non-cultivables**



Écologie de ces plantes mal connue
Menaces sur ces espèces peu évaluées



Exposition de ces plantes
**aux changements
globaux**

**Préambule :
logistique du cours
et
informations diverses**

Salles informatiques

Deux lieux

Bâtiment **Boucherle** (campus de La Tronche)

- salles 106 et 107 (1er étage)
- salles **hybrides** 101 et 102 (1er étage)
→ prenez vos ordinateurs/tablettes

IFPS (campus de Saint-Martin-d'Hères)
Salles Info 001 et 011 (rez-de-chaussée)

Voir les localisations sur [la carte](#)



Ordinateur/tablette en cours

Les salles informatiques sont équipées

Vous pouvez apporter votre ordinateur/tablette à **tous les cours**
y compris au **contrôle continu de statistiques**

Si vous n'avez pas d'ordinateur ou de tablette et que vous souhaitez en obtenir un vous pouvez

- Solliciter un prêt d'ordinateur grâce au dispositif "Étuprêt?" ([Aides informatique à l'UGA](#))
- Aller voir le [Camio.net](#) atelier de réparation mobile
- Accédez à des ordinateurs dans [les BU](#) et dans les [salles informatiques libre-service](#)

Réseau Wifi : connectez-vous à eduroam

- **eduroam** : réseau de **très bonne qualité** disponible partout à l'UGA (et accessible dans la plupart des établissements d'enseignement supérieur européens)
- Pour vous y connecter (y compris sur mobile) allez sur cat.eduroam.org
- Choisissez **l'UGA** et télécharger l'installateur
- On vous demandera des identifiants qui seront sous la forme
votre_identifiant@univ-grenoble-alpes.fr (7 lettres du nom + première lettre prénom)

Mot de passe = mot de passe de votre compte UGA

- Tout est résumé sur [la page dédiée des services numériques](#)

Utilisation des IA génératives en cours

Pose un grand nombre de problèmes
(éthiques, environnementaux, sociaux, juridiques)

Il faut se confronter à la difficulté par soi-même pour triompher
→ vous ne faites pas le même effort à trouver un bon “*prompt*”

Les séances de TD sont en petit groupe
→ vous pouvez nous poser des questions directement

Si vous cherchez d'autres explications de qualité en statistiques
→ voir la liste d'ouvrages recommandés en fin de cours
→ voir les vidéos recommandées sur UNESS

Prise de notes manuscrites vs. sur ordinateur

Notes prises sur ordinateurs = plus de prise de notes

Notes prises à la main = meilleure réflexion sur le contenu (priorisation, schéma, etc.)

Les étudiants prenant leurs notes à la main ont de meilleures **notes d'UE** (méta-analyse [Flanigan et al. 2024](#))

Les ordinateurs tendent à vous distraire en cours → pas les notes papier

=> Je vous recommande de prendre vos notes à la main

Prendre soin de sa santé mentale

- La première année d'étude universitaire est un moment de transition
- Cela peut être difficile à vivre pour vous (changement de ville, changement d'amis·es, vie seul·e, etc.)
- Il existe plusieurs dispositifs pour prendre soin de votre santé mentale à l'UGA (voir [la page dédiée](#))
- Si vous avez besoin d'un professionnel de santé prenez rendez-vous au [service de santé étudiante de Grenoble](#)
- Plus largement, vous pouvez vous référer à la [page "Santé et Bien-Être"](#) de l'UGA



Programme du cours

Modalités d'Évaluation

Répartition équitable entre différents examens :

- Contrôle continu de probabilités (20% de la note)
→ examen papier d'une heure
- Contrôle continu de statistiques 1 (20% de la note)
→ examen en salle informatique d'une heure
- Contrôle continu de statistiques 2 (20% de la note)
→ examen en salle informatique d'une heure
- Examen terminal de probabilités/statistiques (60%)
→ examen papier d'une heure

vendredi 2 octobre
Boucherle 208

lundi 2 novembre
Boucherle Info 103

vendredi 4 décembre
Boucherle Info 107

lundi 16 décembre
Jean Roget TD 03

Précision sur les CC de statistiques

Contrôle continu de statistiques

- En salle informatique (**y compris avec vos ordinateurs/tablettes**)
- Analyse de données à faire avec R
- **Accès à tous les TD passés du semestre**
- **Tous documents autorisés**
(mais pas de **recherche en ligne**, ni d'utilisation d'**IA générative**)

Organisation ce semestre

- 5 cours magistraux de 2h
- 12 séances de TD de 1h30
- 2 séances de contrôle continu en statistiques

Lien avec le cours de l'option Santé

L'option Santé propose des cours de biostatistiques aussi
(avec J. Labarere)

Vous allez revoir les notions ici et les mettre en pratique

- Types de variables
- Paramètres d'une variable
- Tests statistiques

Vous pouvez poser des questions sur les liens entre ces cours

Aujourd'hui

Pourquoi faire des statistiques ?

Statistiques descriptives

Représentation graphique

Introduction aux Statistiques inférentielles


Calcul d'intervalles de confiance

Pourquoi faire des statistiques ?

Définition

Statistique : branche appliquée des mathématiques qui s'intéresse aux **données**, les présente et les analyse

Collecter les données, les visualiser, et les analyser



Importance des statistiques en santé

Les statistiques sont utiles pour répondre à une question avec des données

- Efficacité d'un nouveau médicament par rapport à l'existant
- Prise de décision basée sur des preuves
- Suivre une cohorte de personnes et analyser leur santé
- Étudier une épidémie pour en suivre la tendance



Histoire des statistiques

Examen des fonctionnaires impériaux chinois peint par Qiu Ying
~1540, domaine public via [Wikimedia Commons](#)



Histoire des statistiques

Souvent nécessaire par l'État :
recensement et étude de mortalité
(étymologie du mot **statistique**)

XVII^e siècle : premiers concepts de dénombrements

XVIII^e-XIX^e siècle : Concepts mathématiques (étude scientifique des probabilités)

XX^e siècle : **Ronald Fisher** (1890-1962) et méthodes modernes (+ méthodes computationnelles)

Age $\bar{x}$	Généralions							
	1625- 1649	1650- 1674	1675- 1699	1700- 1724	1725- 1744	1745- 1769	1770- 1790	1800- 1825
0	291	286	269	243	200	219	231	170
1	268	220	236	222	169	163	168	114
5	124	105	109	113	97	89	104	43
10	44	53	50	53	49	89	40	40
15	56	78	64	49	62	46	35	25
20	59	61	37	46	37	41	50	36
25	56	66	69	71	58	48	53	44
30	52	84	73	52	41	51	42	77
35	117	97	90	72	49	51	52	63
40	146	75	88	87	58	56	61	74
45	116	115	109	117	60	85	68	87
50	163	136	182	115	80	114	86	115
55	230	159	178	160	182	146	118	139
60	195	207	298	221	205	178	188	159
65	312	262	429	252	320	247	257	225
70	436	459	449	452	364	345	387	361
75	638	463	636	484	402	485	495	535
80	682	715	847	591	710	641	708	630
85	781	769	1000	755	710	847	713	941



Florence Nightingale : pionnière des statistiques en Santé (1820-1910)

Femme bourgeoise britannique née en 1820

S'engage en tant qu'infirmière de guerre en 1854
pendant la guerre de Crimée

Modernise les pratiques infirmières et sauvent des vies
en le faisant

Fondatrice de la première école laïque d'infirmières

Pionnière de la visualisation de données






DIAGRAM OF THE CAUSES OF MORTALITY IN THE ARMY IN THE EAST.

2.
APRIL 1855 TO MARCH 1856.



1.
APRIL 1854 TO MARCH 1855.



The Areas of the blue, red, & black wedges are each measured from the centre as the common vertex.
The blue wedges measured from the centre of the circle represent area for area the deaths from Preventable or Mitigable Zymotic diseases; the red wedges measured from the centre the deaths from wounds; & the black wedges measured from the centre the deaths from all other causes.
The black line across the red triangle in Nov' 1854 marks the boundary of the deaths from all other causes during the month.
In October 1854, & April 1855, the black area coincides with the red; in January & February 1855, the blue coincides with the black.
The entire diagram may be compared by following the blue, the red, & the black lines enclosing them.

Rôle actuel des biostatistiques

- Dans la **recherche clinique** :
conception d'études, analyse de données
- En **épidémiologie** :
étude des facteurs de risque,
modélisation des épidémies
- En **génomique** :
Analyse des données massives du séquençage
- **Développement de médicament** :
de la découverte à l'autorisation de mise sur le marché



Principe des statistiques : étudier la variabilité

On travaille sur des phénomènes n'étant pas prédictibles




Figure AR6 WG1
rapport du GIEC 2021
Prédictions de l'anomalie de température

=> Les statistiques cherchent à **maîtriser l'incertitude** pour extraire de l'information des données

Statistiques descriptives
(= on compte et on décrit les données)

Statistiques Descriptives ?

Décrire les données =
compter et visualiser les données


Calculer des indicateurs pour formuler des
hypothèses

Présenter un **résumé des données**
(graphiques ou indicateur chiffré)

Remaining life expectancy at different ages, World, 2021

The remaining period life expectancy¹ of people who have reached a given age.


Our World
in Data



Data source: Human Mortality Database (2023); United Nations - World Population Prospects (2022)
OurWorldinData.org/life-expectancy | CC BY

1. Period life expectancy: Period life expectancy is a metric that summarizes death rates across all age groups in one particular year. For a given

Nature des variables



Exemples

Couleur de yeux :
noirs, marrons, verts, etc.

Échelle de douleur :
Faible, moyenne, forte

Nombre de jours
d'hospitalisation

La taille d'un individu :
1,67m

Var. Quantitatives : Indicateurs de position

=> Résume l'ordre de grandeur de l'ensemble des données

Moyenne

Somme pondérée des valeurs

$$\hat{x} = \frac{1}{n} \sum_{i=1}^n x_i$$


Médiane

Valeur qui scinde l'échantillon en deux
(=50% des valeurs inférieures et 50%
des valeurs supérieures)

1, 6, **13**, 16, 19

Mode

Valeur la plus fréquemment observée




Quantiles : autres indicateurs de position

Définition : Valeurs qui divisent le jeu de données en intervalles de probabilités égales

La **médiane** divise les données en deux intervalles de 50%

Quantiles particuliers :

- Les **quartiles** divisent les données en **4 intervalles**, le **premier quartile Q1**, la **médiane** (ou **deuxième quartile Q2**), et le **troisième quartile Q3**
- Les **déciles** divisent un jeu de données en **dix intervalles**
- Les **centiles** divisent un jeu de données en **cent intervalles**
- En combien d'intervalles divisent les **quintiles** ?



En cinq intervalles
(= 4 valeurs)

Comparaison des indicateurs de position

Moyenne	Facile à calculer mais très sensible aux valeurs extrêmes ! (= pas robuste)
Médiane	Indicateur précis et robuste
Mode	Intéressant uniquement avec variables discrètes
Quantile	Renseigne uniquement sur une partie de la distribution

Indicateurs de dispersion (1/2)

=> Résume la **variabilité** des données par rapport à un indicateur de position

Variance

Sommes des écarts au carré à la moyenne


$$s^2 = \frac{1}{n} \sum_{i=1}^n (\hat{x} - x_i)^2$$

Écart-type

Racine carré de la variance

$$s = \sqrt{s^2}$$

Faible variance



Indicateurs de dispersion (2/2)

Étendue

Écart entre la plus grande et la plus petite valeurs des données


$$X_{\max} - X_{\min}$$

Écart Interquartile

Écart entre **Q3** et **Q1**
il contient 50% des observations par définition

$$IQR = Q_3 - Q_1$$

*InterQuartile
Range*



Comparaison des indicateurs de dispersion

Variance /
Écart-type

Facile à calculer mais peu robuste et peu intuitif

Étendue

Facile à calculer et interpréter mais très sensible
aux valeurs extrêmes

Écart
Interquartile


Plus difficile à interpréter
mais, comme les quartiles, très robuste

Représentation graphique

En statistiques descriptives, on va résumer nos données par des graphiques

Les graphiques à utiliser dépendent de la **nature de la variable** (quantitative vs. qualitative)

Quels types de graphiques connaissez-vous ?



Exemple de données

Données de 20 patient · es : âge, poids, sexe, et groupe sanguin


ID	Âge	Poids	Sexe	Groupe Sanguin
1	45	70.5	F	A+
2	32	65.2	M	O-
3	58	82.1	M	B+
4	29	59.8	F	AB+
5	51	77.3	F	A-
⋮	⋮	⋮	⋮	⋮
20	35	66.8	F	AB-

Représenter une variable qualitative

Diagramme en barre (= *barplot*)

hauteur des barres = fréquence de la modalité


Groupe Sanguin	A-	A+	AB-	AB+	B-	B+	O-	O+
Effectifs	2	4	2	2	2	2	2	4



Représenter une variable qualitative

Diagramme en secteurs (=camemberts)

Largeur des secteurs proportionnelle aux effectifs




Représenter une variable quantitative

Histogramme


Représente la distribution d'une variable quantitative

/!\ la largeur du pas modifie l'histogramme /!\

Histogramme du poids




Histogramme du poids



Représenter une variable quantitative


Boîte à moustaches (= *boxplot*)

Représentation simplifiée de la distribution d'une variable quantitative



Attention sur R
les moustaches
s'étendent
jusqu'à
 $Q1 - 1,5 * IQR$
et
 $Q3 + 1,5 * IQR$

$$IQR = Q_3 - Q_1$$




Statistiques inférentielles
(= on suppose des choses sur les
données et on en déduit d'autres)

Échantillon d'une population


Jamais d'observation de la totalité de la **population**

Population



n individus
=
taille de l'échantillon


Échantillon



On cherche à déduire des propriétés de la **population** à partir de l'**échantillon**

Représentativité d'un échantillon

Échantillon



Non-représentatif (dépend de la question)

Étudier population de sportves · fs pour en déduire des choses sur la population générale

Étude en santé mentale *via* formulaire en ligne volontaire → pas aléatoire



Représentatif

Tirage **aléatoire** (tous les individus ont même chance d'être tiré) et **indépendant** (le tirage d'un individu ne dépend pas du tirage d'un autre)

Taille de l'échantillon influence résultat statistique

Estimateur et estimation


On **estime** les valeurs de **paramètres** de la **population** à partir des **données** de l'**échantillon**

		Proportion	Moyenne	Variance
Population		p	μ	σ^2
Échantillon		$\hat{p}$	m	s^2

Avec plusieurs échantillons l'**estimateur** (= la formule de calcul) ne change pas mais l'**estimation** (= la valeur) change

Fluctuations d'échantillonnage

On peut tirer différents d'échantillons d'une population



Les différences entre moyennes sont dues aux
différences entre échantillons
→ au **hasard**
(=fluctuations d'échantillonnages)

Exemple de situation

On mesure la glycémie à jeun de 40 patients d'un service hospitalier

La moyenne observée est de 1,05 g/L

Peut-on dire que la moyenne de la population de patients est exactement 1,05 g/L ?

Non !

Un autre échantillon aura certainement une autre moyenne


La moyenne de notre échantillon est elle-même une variable aléatoire


Exemple de situation

On mesure la glycémie à jeun de 40 patients d'un service hospitalier

La moyenne observée est de 1,05 g/L

Peut-on dire que la moyenne de la population de patients est exactement 1,05 g/L ?

Échantillon  m


Population  μ

La moyenne de l'échantillon m est une variable aléatoire
qui estime μ la moyenne de la population

Retour au Théorème Central Limite


Échantillon m

Si on répète l'échantillonnage suffisamment de fois les moyennes observées se répartissent selon la distribution d'échantillonnage de la moyenne



Histogramme des moyennes observées de beaucoup d'échantillons

Retour au Théorème Central Limite (TCL)




Si on répète suffisamment l'échantillonnage ($n > 30$) le TCL nous dit que :

- La distribution des moyennes des échantillons suit une loi **normale**
- Avec une moyenne μ
- Et un écart type de $\sigma/\sqrt{n}$ qu'on appelle **erreur standard**


Autre exemple

Tirage aléatoire de nombreux échantillons de 40 individus

Population : exponentielle décroissante



Distribution des moyennes des échantillons



Intervalle de confiance : interprétation

Les formules ne sont pas si importantes mais le **principe** si!

$$\text{Intervalle de confiance à } X\% = \left[\text{Moyenne observée} - \frac{\text{Variabilité de l'échantillon}}{\sqrt{\text{Taille de l'échantillon}}} ; \text{Moyenne observée} + \frac{\text{Variabilité de l'échantillon}}{\sqrt{\text{Taille de l'échantillon}}} \right]$$

Moyenne observée

Variabilité de l'échantillon

Taille de l'échantillon

Terme de distribution à X%

L'intervalle de confiance quantifie la **précision** avec laquelle on connaît la moyenne de la population

Plus la **variabilité** augmente plus l'intervalle... (grandit ou rétrécit ?) **grandit**

Plus la **taille** de l'échantillon augmente plus l'intervalle... ? **rétrécit**

Exemple : fréquence cardiaque

On veut la fréquence cardiaque au repos des étudiant·es de Licence
(moyenne de la population = 64 bpm)

On la mesure chez 10 étudiant·es pris·es aléatoirement :

62 | 55 | 57 | 64 | 73 | 76 | 66 | 66 | 64 | 62

Moyenne observée : 64,5 bpm


Écart-type observé : 2,5

Exemple : fréquence cardiaque

Tirons 100 échantillons de 10 étudiant·es

Représentons les IC à 95%

Ici, **trois d'entre eux** ne contiennent pas la vraie valeur de **la moyenne**



Résumé

Fonctionnement des TD

Principe des plateformes

- Cours sur la plateforme **DOORS**
<https://doors.univ-grenoble-alpes.fr>
(accessible avec votre compte UGA)



- Utilisation du le logiciel **JupyterLab**



- *notebooks* qui fonctionnent avec le langage de programmation **R**
- Langage proche de Python, adapté aux statistiques



Principe des TD

- Avec vos ordinateurs ou ceux de la salle **connectés à Internet**
- Connexion à **DOORS**
- Ouverture du *notebook* de la séance (~1 par séance)
- Fonctionnement en semi-autonomie
- Exercice d'application en fin de séance
- Exercice d'application à la maison d'une séance à l'autre


**Des livres disponibles à la BU pour vous
aider dans vos apprentissages/révisions**

Livres de statistiques et de R

Les livres cités dans les diapositives suivantes sont disponibles à la Bibliothèque Universitaire de Médecine Pharmacie (BUMP)

Ils couvrent l'ensemble du programme de statistiques (et vont parfois plus loin !) en utilisant R pour le réaliser
Ce sont des **excellents compléments au cours**

Retrouvez les horaires de la BUMP



Lalanne, Christophe. *Biostatistique et analyse informatique des données de santé avec R* / Christophe Lalanne, Mounir Mesbah. ISTE editions, 2016.

Cote : WA 950/1035-1

3 exemplaires

Notice de bibliothèque

Statistiques descriptives à régression logistique
+ épidémiologie et survie



Frédéric Bertrand • Myriam Maumy-Bertrand

Initiation à la statistique avec R

4^e ÉDITION



DUNOD

Bertrand, Frédéric. *Initiation à la statistique avec R* / Frédéric Bertrand, Myriam Maumy-Bertrand. 4^e édition, Dunod, 2023.

Cote : QA 276/1021/4

3 exemplaires

[Notice de bibliothèque](#)

Statistiques descriptives à ANOVA 1

Olivier Marchal

Statistiques
appliquées

avec introduction au logiciel R



Marchal, Olivier. *Statistiques appliquées avec introduction au logiciel R* / Olivier Marchal. Ellipses, 2018.

Cote : QA 276/1022

1 exemplaire

Notice de bibliothèque

Statistiques descriptives à ANOVA2