

Cours 2 : Tests d'ajustement et d'indépendance

MCBT1U16

Mathématiques / Statistiques 2
L1 Biotechnologie S2 – 2024-2025

Matthias Grenié

(matthias.grenie@univ-grenoble-alpes.fr)



Le Néron près de Proveyzieux, par Charles BERTIER, 1887,
Musée de Grenoble, Domaine public. Crédits
photographiques : Ville de Grenoble / Musée de
Grenoble-J.L. Lacroix

Qu'avons-nous vu à la séance précédente ?

Aujourd'hui

Principe des tests d'ajustements

Test d'ajustement de Kolmogorov-Smirnov

Test du χ^2 d'ajustement

Test du χ^2 d'homogénéité

Test du χ^2 d'indépendance


Tests d'ajustements pour une variable continue

Principe des tests d'ajustement (ou d'adéquation)

On cherche à savoir si nos données se distribuent selon une distribution attendue

Exemple

La taille des étudiant·es de Licence
Biotechnologies suit-elle une loi normale ?



Quel test connaissez-vous pour répondre à cette question ?

Le test de **Shapiro-Wilk** est un **test d'ajustement** aussi !

Rappels sur le test de Shapiro

Exemple : taille de 12 étudiantes = 157, 169, 152, 166, 160, 166, 158, 154, 168, 158, 163, 161

Test de Shapiro

Hypothèses

H_0 : L'échantillon suit une loi normale

H_1 : l'échantillon ne suit pas une loi normale

→ on veut souvent ne pas rejeter H_0

→ fonction sur R **shapiro.test()**

```
> shapiro.test(tailles_femmes)

      Shapiro-Wilk normality test

data:  tailles_femmes
W = 0.95827, p-value = 0.7589
```

Rappels sur le diagramme quantile-quantile

Exemple : taille de 12 étudiantes = 157, 169, 152, 166, 160, 166, 158, 154, 168, 158, 163, 161

On reporte chaque valeur sur l'axe y
On calcule un nombre égal de quantiles équitabement répartis à partir d'une loi normale centrée réduite (moyenne = 0, écart-type = 1)
→ donne la valeur sur l'axe x

12 points = 12 quantiles équitabement répartis


Premier point = calcul du quantile à 4,17% = -1,73

On représente tous ces points

→ On obtient une ligne

→ si c'est une droite
notre échantillon suit une loi normale

```
qqnorm(tailles_femmes)  
qqline(tailles_femmes)
```




Plus général que le test de Shapiro-Wilk : le test de Kolmogorov-Smirnov

On cherche à comparer la **distribution** de notre échantillon à une **distribution théorique**

Principe

- 1) On calcule la **fonction de répartition empirique** de notre échantillon
- 2) On utilise la **fonction de répartition** de la loi **théorique**
- 3) On compare les deux fonctions de répartition en calculant l'**écart maximum observé**
- 4) Si l'écart est grand → **distribution** empirique **différente**
Sinon → **distribution** empirique **conforme**




Fonction de répartition $F(x) = P(X \leq x)$

Point sur la fonction de répartition

Fonction de répartition
(définition mathématique)

$$F(x) = P(X \leq x)$$

Fonction de répartition
de la distribution normale centrée-réduite



On lit le graphique comme ceci :

Pour une loi normale centrée-réduite **20%**
des valeurs sont inférieures à **-0,84**

Quelle proportion est
inférieure ou égale à 0 ?

50% !

Test d'ajustement à une distribution théorique : test de Kolmogorov-Smirnov

Hypothèses

H_0 : La variable suit la distribution donnée $\leftrightarrow H_0 : F_n(x) = F(x)$

H_1 : La variable ne suit pas la distribution donnée $\leftrightarrow H_1 : F_n(x) \neq F(x)$


Avec $F_n(x)$ la fonction de répartition de la variable d'intérêt et $F(x)$ celle de la distribution théorique

Aucune condition d'application


Distributions théoriques sur R

R contient par défaut de nombreuses distributions de probabilités pour les utiliser il faut préciser leur nom sous la forme **p + nom de la distribution()**


Distribution normale (= pnorm())




Distribution uniforme (= punif())



Distribution exponentielle (= pexp())



Distribution t (= pt())



Test d'ajustement à une distribution théorique : test de Kolmogorov-Smirnov

Fonction sur R

```
ks.test(x, "loi_theorique", parametres_de_la_loi)
```

```
> # Données normales  
> donnees_norm = rnorm(25, mean = 4, sd = 0.5)  
> ks.test(donnees_norm, "pnorm", 4, 0.5)
```

Exact one-sample Kolmogorov-Smirnov test

```
data:  donnees_norm  
D = 0.21487, p-value = 0.1714  
alternative hypothesis: two-sided
```

On prend $\alpha = 3,8\%$

$p > \alpha = 3,8\%$, donc, on ne peut pas rejeter H_0 , donc le test de Kolmogorov-Smirnov nous dit qu'elles suivent bien une loi normale

Test d'ajustement à une distribution théorique : test de Kolmogorov-Smirnov

```
> # Données exponentielles  
> donnees_exp = rexp(25, rate = 1)  
> ks.test(donnees_exp, "pexp", 1)
```

Exact one-sample Kolmogorov-Smirnov test

```
data:  donnees_exp  
D = 0.19495, p-value = 0.2621  
alternative hypothesis: two-sided
```

On prend $\alpha = 3,8\% = 0,038$

On observe $p > \alpha$, donc, on ne peut pas rejeter H_0 , donc le test de Kolmogorov-Smirnov nous dit que notre échantillon suit bien une loi exponentielle

Limites des tests d'ajustement

Pour tester la normalité il vaut mieux utiliser un test de Shapiro-Wilk plutôt qu'un test de Kolmogorov-Smirnov

Si on a beaucoup de données, il vaut mieux utiliser un diagramme quantile-quantile

Le diagramme quantile-quantile peut s'étendre à **n'importe quelle distribution**

On peut aussi l'utiliser pour comparer la distribution de **deux échantillons**

En pratique, on combine les méthodes **graphique et statistique**

Test d'ajustement pour une variable catégorielle

Oui mais,... si la distribution est catégorielle ?


Exemple

Distribution des régimes alimentaires en France ([source](#))

Régime alimentaire	Omnivore 🍖 (avec viande)	Flexitarien 🍌 (baisse volontaire)	Sans viande 🥑 (végéta*iens)
Proportion	74%	23%	3%

200 étudiant·es de Licence Biotechnologies (inventée 🌟)

Régime alimentaire	Omnivore 🍖 (avec viande)	Flexitarien 🍌 (baisse volontaire)	Sans viande 🥑 (végéta*iens)
Nombre	140	40	20



Les régimes alimentaires des étudiant·es sont-ils représentatifs de ceux en France ?

Test du χ^2 (khi-deux) d'ajustement

L'objectif du test est de tester l'adéquation d'une répartition observée (en classes) à une répartition théorique

Principe

On utilise la **répartition théorique** pour calculer les **effectifs théoriques**

On compare les **effectifs observés** aux **effectifs théoriques**

S'ils sont "**suffisamment proches**"

→ on conclut que nos données se répartissent selon la distribution théorique

S'ils sont "**suffisamment éloignées**"

→ on conclut que nos données ne se répartissent pas selon la distribution théorique

Test du χ^2 (khi-deux) d'ajustement

Hypothèses

H_0 : La répartition observée est conforme à la répartition théorique

H_1 : La répartition observée dévie de la répartition théorique

Condition d'application :

Il faut que les effectifs théoriques attendus soient tous ≥ 5

Test du χ^2 (khi-deux) d'ajustement

Effectifs totaux observés = 200 (étudiant·es de Licence Biotechnologies)

Régime alimentaire	Omnivore 🍖 (avec viande)	Flexitarien 🍌 (baisse volontaire)	Sans viande 🥑 (végéta*iens)
Proportion théorique	74%	23%	3%
Effectifs théoriques	$200 \cdot 0,74 = 148$	$200 \cdot 0,23 = 46$	$200 \cdot 0,03 = 6$
Effectifs observés	140	40	20

Calcul de la statistique du χ^2

$$\chi^2 = \sum_i \frac{(\text{effectifs observés}_i - \text{effectifs théoriques}_i)^2}{\text{effectifs théoriques}_i}$$
$$= \frac{(140 - 148)^2}{148} + \frac{(40 - 46)^2}{46} + \frac{(20 - 6)^2}{6}$$

$$\chi^2 = 33.88$$

On compare cette valeur à une loi de χ^2 avec
3 (n. catégories) – 1 = 2 degrés de liberté

$$p = 4,4 \cdot 10^{-8}$$

Test du χ^2 (khi-deux) d'ajustement sur R

Fonction sur R

```
chisq.test(x, p = proportions_theoriques)
```

Réalisation du Test

```
> chisq.test(
  c(140, 40, 20),          # Effectifs observés
  p = c(0.74, 0.23, 0.03) # Proportions théoriques
)

Chi-squared test for given probabilities

data:  c(140, 40, 20)
X-squared = 33.882, df = 2, p-value = 4.392e-08
```

alpha = 3,8%

On observe $p \ll \alpha = 3,8\%$, donc on rejette H_0 , ce qui signifie que les régimes alimentaires des étudiants de biotech. ne sont pas représentatifs de ceux en France

Test du χ^2 (khi-deux) d'ajustement sur R

Il faut vérifier les attendus aussi sur R !

Pour ce faire on stocke le résultat du χ^2
puis on accède aux effectifs théoriques avec **...\$expected**

```
> regimes = chisq.test(  
  c(140, 40, 20),          # Effectifs observés  
  p = c(0.74, 0.23, 0.03) # Proportions théoriques  
)  
> regimes$expected  
[1] 148  46   6
```

- Si les conditions d'application du test du χ^2 ne sont pas vérifiées
R va quand même nous donner un calcul et une *p-value* associée
→ nous **ne pouvons** et **ne devons pas l'interpréter** ●

Test du χ^2 (khi-deux) d'homogénéité

Même principe que pour le χ^2 d'ajustement mais on **compare maintenant deux distributions observées** et on cherche à savoir si elles sont identiques ou non

On compare les régimes alimentaires des étudiant·es en Licence Biotech (200 étudiant·es) vs. Licence Biodiversité (250 étudiant·es)

Régime alimentaire	Omnivore 🍖 (avec viande)	Flexitarien 🔍 (baisse volontaire)	Sans viande 🥑 (végéta*iens)
Licence Biotech.	140	40	20
Licence Biodiversité	148	60	42

Ces deux distributions sont-elles semblables ?

Test du χ^2 (khi-deux) d'homogénéité

Régime alimentaire	Omnivore 🍖 (avec viande)	Flexitarien 🍌 (baisse volontaire)	Sans viande 🥑 (végéta*iens)
Licence Biotech.	140	40	20
Licence Biodiversité	148	60	42

```
> chisq.test(matrix(c(140, 40, 20, 148, 60, 42), nrow = 2, byrow = TRUE))
```

Pearson's Chi-squared test

```
data: matrix(c(140, 40, 20, 148, 60, 42), nrow = 2, byrow = TRUE)
X-squared = 6.554, df = 2, p-value = 0.03774
```

On observe $p=0.0377$ très proche de $\alpha = 3,8\%$, donc on ne peut pas conclure
→ il nous faudrait un échantillon plus important

Questions sur les tests d'ajustement pour vous



Question 1

Un test d'ajustement ça sert à...

- A) Vérifier si un échantillon suit une distribution théorique donnée
- B) Comparer deux échantillons entre eux
- C) Mesurer la qualité d'un modèle de régression
- D) Vérifier si une variable a un effet significatif sur une autre
- E) Déterminer si des données sont issues d'un processus aléatoire

Bonne réponse : **A**

Question 2

Le test de Shapiro-Wilk est utilisé pour...

- A) Vérifier uniquement la normalité d'une distribution
- B) Comparer deux distributions quelconques
- C) Tester l'indépendance entre deux variables
- D) Vérifier l'homogénéité des variances
- E) Détecter des valeurs aberrantes

Bonne réponse : **A**

Question 3

Le test de Kolmogorov-Smirnov permet de...

- A) Tester l'adéquation à n'importe quelle distribution continue
- B) Comparer deux échantillons indépendants
- C) Vérifier uniquement la normalité d'une distribution
- D) Tester l'indépendance entre deux variables
- E) Comparer les moyennes de deux populations

Bonnes réponses : **A, B (pas vu en cours)**

Question 4

Le test du chi-deux d'ajustement est particulièrement adapté pour...

- A) Les distributions discrètes
- B) Les très petits échantillons
- C) Comparer plusieurs échantillons simultanément
- D) Tester l'indépendance entre deux variables
- E) Vérifier l'homogénéité des variances

Bonne réponse : **A**

Question 5

Quand un test d'ajustement rejette l'hypothèse nulle, cela signifie que...

- A) L'échantillon ne suit probablement pas la distribution théorique testée
- B) L'échantillon suit certainement la distribution théorique testée
- C) Il y a une erreur dans les calculs
- D) La taille de l'échantillon est trop petite
- E) Les données contiennent des valeurs aberrantes

Bonne réponse : **A**

Test d'indépendance entre deux variables qualitatives

Principe du χ^2 d'indépendance

On a deux variables **qualitatives** et on cherche à tester si elles sont **associées**

Exemple

Y a-t-il une association entre genre et niveau de diplôme ?

Diplôme	Femmes	Hommes	Total
Brevet ou moins	183	287	470
CAP/BEP	207	271	478
Bac	183	173	356
Bac +2	166	134	300
> Bac +2	261	235	496
Total	1000	1100	2100

Recensement de 2 100 personnes

On peut avoir des attendus à l'aide
des **sommes marginales**

χ^2 d'indépendance : Hypothèses & Condition d'application

Hypothèses

H_0 : Les deux variables ne sont pas liées

H_1 : Les variables sont liées

Il faut que les effectifs attendus soient tous ≥ 5

Calcul du χ^2 d'indépendance

Diplôme	Femmes	Hommes	Total
Brevet ou moins	183	287	470
CAP/BEP	207	271	478
Bac	183	173	356
Bac +2	166	134	300
> Bac +2	261	235	496
Total	1000	1100	2100

On peut avoir des attendus à l'aide des sommes marginales

Sous l'hypothèse de **proportionalité** combien attend-on d'avoir de **femmes ayant le Brevet ou moins** ?

= proportionnel au **nombre de femmes dans l'échantillon** et **de personnes ayant le Brevet ou moins**

$$\begin{aligned} \text{attendu}(\text{femme ayant Brevet ou moins}) &= \frac{470 \times 1000}{2100} \\ &= 223.81 \end{aligned}$$

Calcul du χ^2 d'indépendance

Diplôme	Femmes	Hommes	Total
Brevet ou moins	183 223,8	287 246,2	470
CAP/BEP	207 227,6	271 250,4	478
Bac	183 169,5	173 186,5	356
Bac +2	166 142,9	134 157,1	300
> Bac +2	261 236,2	235 259,8	496
Total	1000	1100	2100

Même principe que pour les tests précédents

Calcul de tous les **effectifs attendus**

Puis calcul de la statistique du χ^2

$$\chi^2 = \sum_i \frac{(\text{effectifs observés}_i - \text{effectifs théoriques}_i)^2}{\text{effectifs théoriques}_i}$$

$$\chi^2 = 31.949$$

Puis on compare cette valeur à une loi de χ^2
à (nbre lignes - 1)*(nbre colonnes - 1) = 4 d.d.l.

$$p = 1,96 \cdot 10^{-6}$$

χ^2 d'indépendance sur R

On utilise encore la fonction `chisq.test()` mais avec le tableau de données

On vérifie les effectifs théoriques d'après R

```
> chisq.test(diplome_genre)$expected
```

	genre	
diplome	femme	homme
brevet_ou_moins	223.8095	246.1905
bep_cap	227.6190	250.3810
bac	169.5238	186.4762
bac_plus_2	142.8571	157.1429
sup_bac_plus_2	236.1905	259.8095

χ^2 d'indépendance sur R

Puis on effectue le test

```
> chisq.test(diplome_genre)
```

```
Pearson's Chi-squared test
```

```
data:  diplome_genre
```

```
X-squared = 31.949, df = 4, p-value = 1.959e-06
```

On a $p \ll \alpha = 0,038$, donc on rejette H_0 , ce qui signifie qu'il y a une association entre genre et niveau de diplôme en France

Résumé d'aujourd'hui (au tableau)

Révision de la démarche statistique

1. Choix d'un **seuil alpha** α (= risque alpha = risque de première espèce)
2. Obtention des **données**
3. **Choix d'un test statistique** à effectuer
4. Spécification des **hypothèses** du test
(H_0 = hypothèse nulle ; H_1 = hypothèse alternative)
5. **Vérification des conditions d'application** du test
(et donc réalisation potentielle d'autres tests)
6. Si conditions vérifiées → **réalisation** du test (sur R)
7. **Interprétation** du test
 1. **Comparaison** de la **p-value** obtenue au seuil **alpha**
 2. **Conclusion** par rapport aux **hypothèses** H_0 et H_1
(= rejet/non-rejet de H_0)
 3. **Interprétation** par rapport aux **données**
(= qu'est-ce que cela signifie concrètement)

Rappels du 1er semestre

Si $p > \alpha$

→ on ne rejette pas H_0

Si $p < \alpha$

→ on rejette H_0

Si p proche de α

→ on ne peut pas conclure

Résumé des deux semestres (au tableau)

Rappel sur R

Exemple

J'ai des données de taux de cholestérol (**chol**) en fonction de l'âge (**age**) et du genre des patients (**genre**, qui vaut "h", "f" ou "autre"). Mon tableau s'appelle **taux**

Je veux d'abord sélectionner tous les patients de plus de 50 ans. **Comment faire sous R ?**

```
taux[taux$age >= 50,]
```

Je veux sélectionner tous les hommes de plus de 50 ans

```
taux[taux$age >= 50 & taux$genre == "h",]
```

Je veux sélectionner les personnes qui ne sont pas des hommes de moins de 30 ans

```
taux[taux$genre != "h" & taux$age < 30,]
```

Exemple 2

J'ai des données de taux de cholestérol (**chol**) en fonction de l'âge (**age**) et du genre des patients (**genre**, qui vaut "h", "f" ou "autre"). Mon tableau s'appelle **taux**

Je veux connaître le nombre de lignes de mon tableau. Comment faire ?

length(taux\$chol) ou bien **dim(taux)**

Je veux obtenir les âges des femmes

taux[taux\$genre == "f", "age"] ou bien **taux\$age[taux\$genre == "f"]**

Je veux obtenir le genre des personnes ayant un taux de cholestérol supérieur à 130 ou d'âge supérieur à 50

taux[taux\$chol > 130 | taux\$age > 50, "genre"]

ou bien

taux\$genre[taux\$chol > 130 | taux\$age > 50]

Quelles questions avez-vous ?