

TD2_Manipulation_de_données

August 25, 2026

1 TD 2 : Manipulation de données

Christelle Gonindard, Matthias Grenié, et François Bettega

1.1 Objectifs

- Extraire une valeur d'un tableau
- Filtrer des lignes d'un tableau
- Sélectionner des colonnes
- Connaître l'utilisation des crochets `[]` pour extraire des informations d'un tableau ou l'alternative avec `subset()`
- Mesurer la taille d'un tableau avec `nrow()`, `ncol()`, et `dim()`

1.2 1. Rappel sur les données

Le jeu de données contient les variables suivantes en colonne : - **hamilton_g1** : Les scores de Hamilton, après 8 mois de traitement pour le groupe 1 ; - **hamilton_g2** : Les scores de Hamilton, après 8 mois de traitement pour le groupe 2 ; - **age_g1** : l'âge des patients du groupe 1 ; - **age_g2** : l'âge des patients du groupe 2 ; - **poids_g1** : le poids des patients du groupe 1 ; - **poids_g2** : le poids des patients du groupe 2 ; - **sexe_g1** : le sexe des patients du groupe 1 ("F" : femme, "H" : homme) ; - **sexe_g2** : le sexe des patients du groupe 2 ("F" : femme, "H" : homme) ; - **urbanisation_g1** : le niveau d'urbanisation dans lequel vivent les patients du groupe 1 ("A" : rural, "B" : urbanisation modéré, "C" : fortement urbanisé) ; - **urbanisation_g2** : le niveau d'urbanisation dans lequel vivent les patients du groupe 2 ("A" : rural, "B" : urbanisation modéré, "C" : fortement urbanisé).

1.3 2. Recharger les données

Quand on ouvre un nouveau notebook, les objets créés et chargés dans les autres notebooks ne sont pas disponibles, il faut donc les charger à nouveau.

Pour mémoire les données sont contenues dans le fichier texte nommé **depression.txt** qui se trouve dans le dossier **data**. Le chemin d'accès complet du fichier est donc **data/depression.txt**. Il faut utiliser la fonction **read.table()** en précisant aussi l'argument **header = TRUE**

```
[1]: # Chargez les données
depression = read.table("data/depression.txt", header = TRUE)
```

Afficher les premières lignes du tableau avec la fonction **head()**

```
[2]: head(depression)
```

		hamilton_g1	hamilton_g2	urbanisation_g1	urbanisation_g2	age_g1	age_g2
		<int>	<int>	<chr>	<chr>	<int>	<int>
A data.frame: 6 × 10	1	43	25	B	B	57	48
	2	29	29	A	B	37	41
	3	34	18	A	A	7	30
	4	39	23	A	A	37	41
	5	40	24	B	A	15	30
	6	41	25	B	B	45	45

1.4 3. Extraction directe de données

Il est possible avec **R** d'extraire des valeurs particulières d'un tableau (*data.frame*). Pour cela, il faut être conscient qu'un tableau est composé de lignes et de colonnes, chaque valeur du tableau a donc un numéro de ligne *i* et un numéro de colonne *j*.

Pour extraire une valeur particulière du tableau, il suffit de préciser à **R** son numéro de ligne et de colonne. Par exemple, nous allons extraire la valeur à la ligne 2 dans la colonne 3 :

```
[3]: # Extraire la valeur de la ligne 2 en colonne 3
# les [] permettent d'extraire une sous partie du tableau
# ce qui est avant la virgule correspond aux lignes et ce qui est après la
#    ↪ virgule correspond aux colonnes
depression[2,3]
```

'A'

Application : Extraire la valeur du tableau qui se situe à la ligne 15 dans la colonne 4

```
[4]: depression[15,4]
```

'A'

On peut aussi extraire toute une ligne ou tout une colonne en ne mettant rien à la place de l'indice de ligne ou de colonne respectivement (**Attention il faut tout même garder la virgule dans les crochets**).

Par exemple, on peut extraire toute la deuxième ligne du tableau avec :

```
[5]: depression[2,]
```

		hamilton_g1	hamilton_g2	urbanisation_g1	urbanisation_g2	age_g1	age_g2
		<int>	<int>	<chr>	<chr>	<int>	<int>
A data.frame: 1 × 10	2	29	29	A	B	37	41

De même, on peut extraire la troisième colonne avec une expression similaire

```
[6]: depression[, 3]
```

1. 'B' 2. 'A' 3. 'A' 4. 'A' 5. 'B' 6. 'B' 7. 'A' 8. 'A' 9. 'A' 10. 'A' 11. 'B' 12. 'A' 13. 'B' 14. 'A' 15. 'A' 16. 'B' 17. 'A' 18. 'B' 19. 'A' 20. 'A' 21. 'B' 22. 'B' 23. 'A' 24. 'A' 25. 'B' 26. 'B' 27. 'A' 28. 'A'

29. 'C' 30. 'B' 31. 'C' 32. 'B' 33. 'C' 34. 'A' 35. 'C' 36. 'A' 37. 'A' 38. 'B' 39. 'B' 40. 'B' 41. 'B'
42. 'B' 43. 'A' 44. 'A' 45. 'B' 46. 'B' 47. 'A' 48. 'A' 49. 'B' 50. 'C'

Application : Extraire la 5ème ligne du tableau, puis extraire la 5ème colonne

```
[7]: # 5ème ligne
depression[5,]

# 5ème colonne
depression[, 5]
```

A data.frame: 1 × 10	hamilton_g1 <int>	hamilton_g2 <int>	urbanisation_g1 <chr>	urbanisation_g2 <chr>	age_g1 <int>	age_g2 <int>
5	40	24	B	A	15	30

1. 57 2. 37 3. 7 4. 37 5. 15 6. 45 7. 41 8. 33 9. 55 10. 46 11. 28 12. 39 13. 30 14. 39 15. 50 16. 42
17. 44 18. 22 19. 36 20. 37 21. 35 22. 62 23. 46 24. 45 25. 56 26. 40 27. 46 28. 45 29. 42 30. 41 31. 37
32. 39 33. 52 34. 45 35. 59 36. 41 37. 15 38. 43 39. 28 40. 72 41. 45 42. 49 43. 47 44. 40 45. 41 46. 23
47. 31 48. 44 49. 42 50. 30

1.5 4. Extraction en fonction de conditions

1.5.1 4.1 Introduction aux conditions

Avant d'aller plus loin dans les extractions de sous tableaux, il est important de bien faire la différence entre = et le ==

Lorsque l'on utilise un signe égal = nous créons une variable, par exemple ici nous allons attribuer la valeur 4 à toto :

```
[8]: # si on tape juste toto, R met un message d'erreur car la variable toto est vide
# le = permet d'affecter une valeur à une variable
toto = 4
toto
```

4

Lorsque nous mettons un ==, nous réalisons un test, c'est à dire qu'on teste l'égalité.

Par exemple on peut tester si toto est égal à 9

```
[9]: toto == 9
```

FALSE

R nous répond faux.

Remarque : Pour tester si une valeur est différente il faut utiliser !=.

On peut par exemple tester si toto est différent de 9

```
[10]: toto != 9
```

TRUE

R nous répond vrai.

1.5.2 4.2. Extraire une valeur ou une série de valeurs

Il est également possible d'extraire des sous groupes de données au sein d'une colonne. Par exemple, à partir de notre tableau de données, nous pouvons extraire parmi la colonne scores de Hamilton du groupe 1, uniquement le score des hommes. Nous appellerons ce nouveau groupe : `hamilton_g1_homme`.

Le principe est le suivant : - On sélectionne la colonne qui nous intéresse, ici il s'agit de `hamilton_g1`, comme si obtenir toutes les valeurs de la colonne avec `$` - Comme on veut extraire des valeurs de cette colonne, on a besoin d'utiliser les crochets `[ ]` - Seul le score des hommes nous intéresse, il est donc nécessaire de préciser à **R** qu'au sein de cette colonne, nous ne garderons que les lignes correspondantes aux hommes (on met l'expression logique dans les crochets)

```
[11]: # Décomposons :  
# 1. on extrait la colonne  
depression$hamilton_g1  
# 2. on veut extraire des valeurs de la colonnes avec '['  
depression$hamilton_g1[  
# 3. on formule l'expression logique pour nos valeurs  
depression$sexe_g1 == "H"  
# 4. on assemble tout  
depression$hamilton_g1[depression$sexe_g1 == "H"]  
  
# 5. on assigne la variable  
hamilton_g1_homme = depression$hamilton_g1[depression$sexe_g1 == "H"]  
hamilton_g1_homme
```

1. 43 2. 29 3. 34 4. 39 5. 40 6. 41 7. 32 8. 36 9. 35 10. 37 11. 43 12. 36 13. 41 14. 37 15. 33 16. 40
17. 38 18. 43 19. 32 20. 32 21. 44 22. 40 23. 36 24. 37 25. 41 26. 43 27. 37 28. 31 29. 47 30. 41 31. 45
32. 42 33. 46 34. 35 35. 49 36. 33 37. 34 38. 44 39. 40 40. 42 41. 44 42. 40 43. 29 44. 36 45. 42 46. 44
47. 32 48. 37 49. 42 50. 45

1. 43 2. 29 3. 34 4. 39 5. 40 6. 41 7. 32 8. 36 9. 35 10. 37 11. 43 12. 36 13. 41 14. 37 15. 33 16. 40
17. 38 18. 43 19. 32 20. 32 21. 44 22. 40 23. 36 24. 37 25. 41 26. 43 27. 37 28. 31 29. 47 30. 41 31. 45
32. 42 33. 46 34. 35 35. 49 36. 33 37. 34 38. 44 39. 40 40. 42 41. 44 42. 40 43. 29 44. 36 45. 42 46. 44
47. 32 48. 37 49. 42 50. 45

1. FALSE 2. TRUE 3. TRUE 4. TRUE 5. TRUE 6. TRUE 7. TRUE 8. TRUE 9. TRUE 10. TRUE
11. TRUE 12. TRUE 13. TRUE 14. FALSE 15. TRUE 16. TRUE 17. FALSE 18. TRUE 19. TRUE
20. TRUE 21. TRUE 22. FALSE 23. TRUE 24. FALSE 25. FALSE 26. FALSE 27. TRUE 28. TRUE
29. FALSE 30. TRUE 31. TRUE 32. TRUE 33. FALSE 34. TRUE 35. TRUE 36. TRUE 37. TRUE
38. TRUE 39. TRUE 40. FALSE 41. TRUE 42. TRUE 43. TRUE 44. TRUE 45. TRUE 46. FALSE
47. TRUE 48. TRUE 49. TRUE 50. TRUE

1. 29 2. 34 3. 39 4. 40 5. 41 6. 32 7. 36 8. 35 9. 37 10. 43 11. 36 12. 41 13. 33 14. 40 15. 43 16. 32
17. 32 18. 44 19. 36 20. 37 21. 31 22. 41 23. 45 24. 42 25. 35 26. 49 27. 33 28. 34 29. 44 30. 40 31. 44
32. 40 33. 29 34. 36 35. 42 36. 32 37. 37 38. 42 39. 45

1. 29 2. 34 3. 39 4. 40 5. 41 6. 32 7. 36 8. 35 9. 37 10. 43 11. 36 12. 41 13. 33 14. 40 15. 43 16. 32

17. 32 18. 44 19. 36 20. 37 21. 31 22. 41 23. 45 24. 42 25. 35 26. 49 27. 33 28. 34 29. 44 30. 40 31. 44
32. 40 33. 29 34. 36 35. 42 36. 32 37. 37 38. 42 39. 45

Entraînement : Extraire le score de Hamilton des personnes du groupe 2 qui se situe dans une zone urbanisée A

```
[12]: hamilton_g2_a = depression$hamilton_g1[depression$urbanisation_g1 == "A"]
      hamilton_g2_a
```

1. 29 2. 34 3. 39 4. 32 5. 36 6. 35 7. 37 8. 36 9. 37 10. 33 11. 38 12. 32 13. 32 14. 36 15. 37 16. 37
17. 31 18. 35 19. 33 20. 34 21. 29 22. 36 23. 32 24. 37

1.5.3 4.3 Extraire un sous-tableau

Dans la section précédente on a vu comment extraire une valeur ou une série de valeur sous la forme d'un vecteur, il est également possible d'extraire un sous-tableau de données. Nous allons par exemple extraire le tableau de données qui est associé aux données du groupe 1, nous l'appellerons `data_g1`.

Le principe est le suivant : - Repérer les colonnes qui sont associées au groupe 1 : ce sont les colonnes impaires 1, 3, 5, 7 et 9. - Ensuite nous voulons récupérer toutes les lignes

Pour extraire plus d'une colonne, il faut préciser les numéros de plusieurs colonnes à l'aide de la fonction `c()`, en donnant les nombres séparés par des virgules. Par exemple, pour extraire les deux premières colonnes d'un tableau nommé `tab` on écrirait `tab[, c(2, 3)]`

```
[13]: # les [] permettent d'extraire une sous-partie du tableau
      # ce qui est avant la virgule correspond aux lignes et ce qui est après la
      # virgule correspond aux colonnes
      # nous ne précisons rien pour les lignes car nous les voulons toutes
      # pour les colonnes nous précisons les valeurs souhaitées
      data_g1 = depression[,c(1, 3, 5, 7,9)]

      # affichons le début du nouveau tableau
      head(data_g1)
```

		hamilton_g1	urbanisation_g1	age_g1	poids_g1	sexe_g1
		<int>	<chr>	<int>	<int>	<chr>
	1	43	B	57	74	F
	2	29	A	37	95	H
A data.frame: 6 × 5	3	34	A	7	84	H
	4	39	A	37	104	H
	5	40	B	15	92	H
	6	41	B	45	85	H

*Application : Extraire un nouveau tableau nommé `data_g2`, qui contient uniquement les colonnes associées au groupe G2

```
[14]: data_g2 = depression[,c(2,4,6,8,10)]
```

Note : On peut aussi extraire des colonnes d'un tableau en utilisant les noms de colonnes entre

guillemets " au sein de la fonction `c()` séparés par des virgules, vous pourriez par exemple tester l'expression `depression[, c("age_g1", "poids_g1", "sexe_g1")]`

À partir du tableau `data_g1`, nous allons sélectionner un nouveau tableau qui ne contient que le résultat des femmes. Le principe est le suivant : - Nous voulons faire une extraction donc il faut utiliser `[]`, - Nous ne gardons que les lignes où la valeur "F" apparaît dans la colonne `sexe_g1` - Puis nous gardons l'ensemble des colonnes (donc on ne met rien après la virgule dans `[]`)

```
[15]: # Décomposons
# 1. Faisons l'extraction avec `[]`
data_g1[]

# 2. préparons l'expression logique sélectionnant les femmes
data_g1$sexe_g1 == "F"

# 3. On assemble le tout
data_g1[data_g1$sexe_g1 == "F", ]

# 4. On stocke la variable
data_g1_femme = data_g1[data_g1$sexe_g1 == "F",]

head(data_g1_femme) # affiche les premières lignes d'un tableau de données
```

	hamilton_g1 <int>	urbanisation_g1 <chr>	age_g1 <int>	poids_g1 <int>	sexe_g1 <chr>
	43	B	57	74	F
	29	A	37	95	H
	34	A	7	84	H
	39	A	37	104	H
	40	B	15	92	H
	41	B	45	85	H
	32	A	41	79	H
	36	A	33	92	H
	35	A	55	76	H
	37	A	46	78	H
	43	B	28	88	H
	36	A	39	83	H
	41	B	30	76	H
	37	A	39	72	F
	33	A	50	75	H
	40	B	42	88	H
	38	A	44	71	F
	43	B	22	89	H
	32	A	36	86	H
	32	A	37	107	H
	44	B	35	90	H
	40	B	62	72	F
	36	A	46	87	H
A data.frame: 50 × 5	37	A	45	73	F
	41	B	56	67	F
	43	B	40	65	F
	37	A	46	95	H
	31	A	45	80	H
	47	C	42	70	F
	41	B	41	85	H
	45	C	37	82	H
	42	B	39	92	H
	46	C	52	74	F
	35	A	45	80	H
	49	C	59	100	H
	33	A	41	80	H
	34	A	15	78	H
	44	B	43	79	H
	40	B	28	78	H
	42	B	72	72	F
	44	B	45	104	H
	40	B	49	88	H
	29	A	47	104	H
	36	A	40	92	H
	42	B	41	82	H
	44	B	23	66	F
	32	A	31	85	H
	37	A	44	81	H
	42	B	42	82	H
	45	C	30	100	H

1. TRUE 2. FALSE 3. FALSE 4. FALSE 5. FALSE 6. FALSE 7. FALSE 8. FALSE 9. FALSE
 10. FALSE 11. FALSE 12. FALSE 13. FALSE 14. TRUE 15. FALSE 16. FALSE 17. TRUE
 18. FALSE 19. FALSE 20. FALSE 21. FALSE 22. TRUE 23. FALSE 24. TRUE 25. TRUE 26. TRUE
 27. FALSE 28. FALSE 29. TRUE 30. FALSE 31. FALSE 32. FALSE 33. TRUE 34. FALSE
 35. FALSE 36. FALSE 37. FALSE 38. FALSE 39. FALSE 40. TRUE 41. FALSE 42. FALSE
 43. FALSE 44. FALSE 45. FALSE 46. TRUE 47. FALSE 48. FALSE 49. FALSE 50. FALSE

	hamilton_g1	urbanisation_g1	age_g1	poids_g1	sexe_g1
	<int>	<chr>	<int>	<int>	<chr>
1	43	B	57	74	F
14	37	A	39	72	F
17	38	A	44	71	F
22	40	B	62	72	F
A data.frame: 11 × 5	24	37	45	73	F
	25	41	56	67	F
	26	43	40	65	F
	29	47	42	70	F
	33	46	52	74	F
	40	42	72	72	F
	46	44	23	66	F

	hamilton_g1	urbanisation_g1	age_g1	poids_g1	sexe_g1
	<int>	<chr>	<int>	<int>	<chr>
1	43	B	57	74	F
14	37	A	39	72	F
17	38	A	44	71	F
22	40	B	62	72	F
A data.frame: 6 × 5	24	37	45	73	F
	25	41	56	67	F

Extraire une tableau `data_g2_femme` qui ne contient que les informations concernant les femmes du groupes 2

```
[16]: data_g2_femme = data_g2[data_g2$sexe_g2 == "F",]
```

1.5.4 4.4 Combiner les conditions

Il est possible de combiner plusieurs conditions lorsque l'on extrait des données d'un tableau grâce aux intructions : - **&** ([esperluette](#)) qui signifie “**et**” : par exemple on veut extraire du tableau les données concernant les femmes de plus de 40 ans (ce qui se traduit par “être une femme et avoir plus de 40 ans”) - **|** ([barre verticale](#) ou *pipe*) qui signifie “**ou**” : par exemple on veut extraire du tableau les données concernant soit les femmes soit les personnes de plus de 40 ans, la différence avec le tableau précédent est qu'il sera possible dans ce tableau d'avoir également des hommes de plus de 40 ans

Les conditions combinées sont alors écrites individuellement et séparées de **&** ou **|**

Appliquer ces deux conditions au tableau `data_g1`

```
[17]: # tableau les données du groupe 1 concernant les femmes de plus de 40 ans
tab1 <- data_g1[data_g1$sexe_g1 == "F" & data_g1$age_g1 > 40,]
head(tab1)

# tableau les données du groupe 1 concernant soit les femmes soit les personnes
↳ de plus de 40 ans
tab2 <- data_g1[data_g1$sexe_g1 == "F" | data_g1$age_g1 > 40,]
head(tab2)
```

		hamilton_g1	urbanisation_g1	age_g1	poids_g1	sexe_g1
		<int>	<chr>	<int>	<int>	<chr>
A data.frame: 6 × 5	1	43	B	57	74	F
	17	38	A	44	71	F
	22	40	B	62	72	F
	24	37	A	45	73	F
	25	41	B	56	67	F
	29	47	C	42	70	F
		hamilton_g1	urbanisation_g1	age_g1	poids_g1	sexe_g1
		<int>	<chr>	<int>	<int>	<chr>
A data.frame: 6 × 5	1	43	B	57	74	F
	6	41	B	45	85	H
	7	32	A	41	79	H
	9	35	A	55	76	H
	10	37	A	46	78	H
	14	37	A	39	72	F

Appliquer ces deux conditions au tableau *data_g2*

```
[18]: # tableau les données G1 concernant les femmes de plus de 40 ans
tab1_bis <- data_g2[data_g2$sexe_g2 == "F" & data_g2$age_g2 > 40,]
head(tab1_bis)

# tableau les données G1 concernant soit les femmes soit les personnes de plus
↳ de 40 ans
tab2_bis <- data_g2[data_g2$sexe_g2 == "F" | data_g2$age_g2 > 40,]
head(tab2_bis)
```

A data.frame: 0 × 5		hamilton_g2	urbanisation_g2	age_g2	poids_g2	sexe_g2
		<int>	<chr>	<int>	<int>	<chr>
		hamilton_g2	urbanisation_g2	age_g2	poids_g2	sexe_g2
		<int>	<chr>	<int>	<int>	<chr>
A data.frame: 6 × 5	1	25	B	48	93	H
	2	29	B	41	92	H
	4	23	A	41	81	H
	5	24	A	30	74	F
	6	25	B	45	98	H
	7	27	B	41	75	H

Application : - Construire un tableau nommé tab1 qui sélectionne les femmes et la classe Urbanisation "A" - Construire un tableau nommé tab2 qui sélectionne les femmes ou la classe Urbanisation "A"

```
[19]: tab1 <- data_g1[data_g1$sexe_g1=="F" & data_g1$urbanisation_g1 == "A",]
      tab2 <- data_g2[data_g2$sexe_g2=="F" | data_g2$urbanisation_g2 == "A",]
```

1.5.5 4.5 Fonction subset() : syntaxe alternative

Une autre façon d'extraire un sous-tableau est d'utiliser la fonction `subset()` (sous-ensemble), elle permet de ne pas avoir à écrire des expressions compliquées mobilisant les crochets `[]` et de filtrer rapidement les lignes. Pour l'utiliser, il faut utiliser le nom du tableau, suivi comme arguments des différentes conditions que vous souhaitez appliquer.

Par exemple, pour filter les femmes du groupe 1, on peut écrire `subset(data_g1, sexe_g1 == "F")`. Testez le ci-dessous

```
[20]: # Première utilisation de subset()
```

```
subset(data_g1, sexe_g1 == "F")
```

		hamilton_g1 <int>	urbanisation_g1 <chr>	age_g1 <int>	poids_g1 <int>	sexe_g1 <chr>
A data.frame: 11 × 5	1	43	B	57	74	F
	14	37	A	39	72	F
	17	38	A	44	71	F
	22	40	B	62	72	F
	24	37	A	45	73	F
	25	41	B	56	67	F
	26	43	B	40	65	F
	29	47	C	42	70	F
	33	46	C	52	74	F
	40	42	B	72	72	F
	46	44	B	23	66	F

De la même façon que plus haut, on peut combiner les conditions en utilisant `&` et `|`. Construisez les tableaux qui prennent les femmes du groupe 1 de niveau d'urbanisation A, puis celles du groupe 2 de niveau d'urbanisation A avec `subset()`.

```
[21]: # Femmes du groupe 1, d'urbanisation A
      subset(data_g1, sexe_g1 == "F" & urbanisation_g1 == "A")
```

```
# Femmes du groupe 2, d'urbanisation A
subset(data_g2, sexe_g2 == "F" & urbanisation_g2 == "A")
```

		hamilton_g1 <int>	urbanisation_g1 <chr>	age_g1 <int>	poids_g1 <int>	sexe_g1 <chr>
A data.frame: 3 × 5	14	37	A	39	72	F
	17	38	A	44	71	F
	24	37	A	45	73	F

		hamilton_g2 <int>	urbanisation_g2 <chr>	age_g2 <int>	poids_g2 <int>	sexe_g2 <chr>
A data.frame: 3 × 5	5	24	A	30	74	F
	11	18	A	29	66	F
	45	23	A	37	73	F

1.6 5. Mesurer les dimensions d'un tableau

Souvent, on veut connaître les dimensions exactes d'un sous-tableau qu'on a extrait : connaître le nombre de colonnes ou de lignes.

Pour les data.frames on peut utiliser plusieurs fonctions, la première, **dim()** nous donne l'ensemble des **dimensions** du tableau. Elle renvoie un vecteur contenant deux nombres. Le premier représente le nombre de lignes et le second le nombre de colonnes du tableau.

Testez la fonction ci-dessous sur le tableau total **depression**:

```
[22]: # Mesure des dimensions du tableau général
dim(depression)
```

1. 50 2. 10

Combien le tableau compte-t-il de lignes et de colonnes ?

Réponse :

Note : la fonction **dim()** renvoie le nombre de lignes puis de colonnes car cela correspond à la convention en mathématiques lorsque l'on décrit une matrice. On donne toujours le nombre de lignes d'abord pour le nombre de colonnes.

De manière analogue, si l'on est intéressé par le nombre de ligne, on peut utiliser la fonction **nrow()** sur un tableau (pour *number of rows*, nombre de lignes en anglais).

Pour le nombre de colonnes, il existe la fonction **ncol()** (pour *number of columns*, nombre de colonnes en anglais).

Utilisez-les pour calculer le nombre de lignes et colonnes du tableau **depression**.

```
[23]: # Nombre de lignes
nrow(depression)

# Nombre de colonnes
ncol(depression)
```

50

10

Question d'application : utilisez ces fonctions pour compter le nombre de lignes et de colonnes sur les tableau **tab1** et **tab2** précédemment créés

```
[24]: nrow(tab1)
nrow(tab2)

ncol(tab1)
```

```
ncol(tab2)
```

3

26

5

5

1.7 En résumé

- Nous avons vu comment extraire des valeurs d'un tableau avec `[]`
- Nous avons vu comment filtrer des lignes avec des expressions logiques (`==`, `!=`, `>`, et `<`)
- Nous avons vu comment sélectionner des colonnes avec `$`
- Nous avons vu comment utiliser la fonction `subset()` pour filtrer les lignes
- Nous avons vu les fonctions `dim()`, `nrow()`, et `ncol()` pour connaître les dimensions des tableaux

1.8 6. Exercices d'applications

1.8.1 6.1 Étude comparative hommes / femmes

A partir de ces deux tableaux de données, réaliser une étude descriptive comparative des hommes, puis des femmes, en répondant aux questions suivantes :

1. Comparer les moyennes et variances empiriques des scores de Hamilton dans les deux tableaux
2. Comparer les médianes et quartiles empiriques des âges dans les deux tableaux

```
[25]: data_g1_homme = depression[depression$sexe_g1 == "H", c(1,3,5,7,9)]
      data_g2_homme = depression[depression$sexe_g2 == "H", c(2,4,6,8,10)]

      "---- Hommes ----"
      # Question 1 :
      mean(data_g1_homme$hamilton_g1)
      var(data_g1_homme$hamilton_g1)

      mean(data_g2_homme$hamilton_g2)
      var(data_g2_homme$hamilton_g2)

      # Question 2
      summary(data_g1_homme$age_g1)
      summary(data_g2_homme$age_g2)

      "---- Femmes ----"
      # data_g1_femme et data_g2_femme ont déjà été créés en section 4.3
      # Question 1 :
      mean(data_g1_femme$hamilton_g1)
      var(data_g1_femme$hamilton_g1)

      mean(data_g2_femme$hamilton_g2)
```

```
var(data_g2_femme$hamilton_g2)
```

```
# Question 2
```

```
summary(data_g1_femme$age_g1)
```

```
summary(data_g2_femme$age_g2)
```

"---- Hommes ----"

37.974358974359

24.8151147098516

24.5111111111111

25.210101010101

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
7.00	34.00	41.00	38.18	45.00	59.00

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
13.00	30.00	36.00	37.16	46.00	55.00

"---- Femmes ----"

41.6363636363636

11.6545454545455

24.8

29.7

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
23.00	41.00	45.00	48.36	56.50	72.00

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
29.0	30.0	37.0	34.4	38.0	38.0

Quelles hypothèses pouvez-vous émettre ?

Hypothèses :

On observe que, pour les deux sexes, les scores de Hamilton moyens sont plus faibles dans le groupe 2 que dans le groupe 1, avec des variances/écarts inter-quartiles assez proches entre les deux groupes. Cette différence descriptive pourrait suggérer un effet du traitement reçu par le groupe 2, mais on ne peut pas l'affirmer à ce stade : rien ne garantit que les deux groupes étaient comparables au départ, et surtout, aucun test statistique n'a encore été réalisé pour savoir si cette différence est significative ou si elle pourrait s'expliquer par la variabilité d'échantillonnage. Nous reviendrons sur cette question avec des tests de comparaison de moyennes dans les prochains TD.

1.8.2 6.2 Comparaison en fonction de l'urbanisation

Donnez à chaque fois le nombre de personnes dans chaque groupe.

1. Représenter graphiquement le score de Hamilton des hommes du groupe 1 en urbanisation de type A

2. Représenter graphiquement le score de Hamilton des hommes du groupe 1 en urbanisation de type B
3. Représenter graphiquement le score de Hamilton des hommes du groupe 2 en urbanisation de type A
4. Représenter graphiquement le score de Hamilton des hommes du groupe 2 en urbanisation de type B.

Vous pouvez essayer de tous les représenter sur le même graphique pour pouvoir plus facilement les comparer.

Quelles hypothèses pouvez-vous émettre suite à ces descriptions ?

```
[27]: # Question 1
boxplot(data_g1_homme$hamilton_g1[data_g1_homme$urbanisation_g1=="A"],
        ↪main="groupe G1, Homme, A")

# Question 2
boxplot(data_g1_homme$hamilton_g1[data_g1_homme$urbanisation_g1=="B"],main="groupe
        ↪G1, Homme, B")


# Question 3
boxplot(data_g2_homme$hamilton_g2[data_g2_homme$urbanisation_g2=="A"],main="groupe
        ↪G2, Homme, A")

# Question 4
boxplot(data_g2_homme$hamilton_g2[data_g2_homme$urbanisation_g2=="B"],main="groupe
        ↪G2, Homme, B")


# Tout en même temps
boxplot(
  data_g1_homme$hamilton_g1[data_g1_homme$urbanisation_g1=="A"],
  data_g1_homme$hamilton_g1[data_g1_homme$urbanisation_g1=="B"],
  data_g2_homme$hamilton_g2[data_g2_homme$urbanisation_g2=="A"],
  data_g2_homme$hamilton_g2[data_g2_homme$urbanisation_g2=="B"],
  names = c("g1-A", "g1-B", "g2-A", "g2-B")
)

# Hypothèses : il semble qu'en plus d'un effet de l'acupuncture il semble y
        ↪avoir un effet de l'urbanisation sur la dépression
# L'environnement le plus urbain semble augmenter la dépression.
```


groupe G1, Homme, A




groupe G1, Homme, B




groupe G2, Homme, A



groupe G2, Homme, B





1.8.3 6.3 Comparaison d'acceptation de crédit

On va reprendre le jeu de données `credit_approval.txt` utilisé dans les exercices du TD précédent

Le fichier `credit_approval.txt` dans le dossier `data/` décrit 50 ménages, formés de couples mariés hétérosexuels, tous deux actifs, qui ont déposé une demande de crédit auprès d'un établissement bancaire. Les variables disponibles sont les suivantes :

- `sal.homme` : logarithme du salaire annuel de l'homme,
- `sal.femme` : logarithme du salaire annuel de la femme,
- `rev.tete` : logarithme du revenu par tête c'est-à-dire total des revenus divisé par le nombre de personnes,
- `age` : logarithme de l'âge de l'homme,
- `acceptation` : accord du crédit par l'organisme prêteur (valeurs : "oui" ou "non"),

- `garantie.supp` : garantie supplémentaire demandée par l'organisme prêteur (valeurs : "caution", "hypothèque" ou "non"),
- `emploi` : type d'emploi occupé par la personne de référence lors de la demande de crédit (valeurs : "cdd" ou "cdi").

1. Combien de couples ont vu leur crédit acceptés sans avoir de garantie supplémentaire

```
[28]: credit = read.table("data/credit_approval.txt", header = TRUE)
```

```
# Première syntaxe
credit[credit$acceptation == "oui" & credit$garantie.supp == "non",]

# Deuxième syntaxe
subset(credit, acceptation == "oui" & garantie.supp == "non")

# => 11 couples
```

		sal.homme <dbl>	sal.femme <dbl>	rev.tete <dbl>	age <dbl>	acceptation <chr>	garantie.supp <chr>	emploi <chr>
	9	7.48	7.25	6.46	3.47	oui	non	cdi
	11	7.28	7.47	6.97	3.56	oui	non	cdi
	14	8.42	8.01	7.83	3.47	oui	non	cdi
	16	7.47	7.59	7.53	3.78	oui	non	cdi
A data.frame: 11 × 7	28	7.63	7.77	6.79	3.66	oui	non	cdi
	29	6.18	6.40	6.30	4.08	oui	non	cdi
	30	7.57	7.53	6.63	3.43	oui	non	cdi
	32	8.03	7.94	7.29	3.78	oui	non	cdi
	35	7.92	7.92	6.82	3.66	oui	non	cdi
	39	8.78	8.58	8.69	3.78	oui	non	cdi
	47	8.17	8.29	8.23	3.95	oui	non	cdi
		sal.homme <dbl>	sal.femme <dbl>	rev.tete <dbl>	age <dbl>	acceptation <chr>	garantie.supp <chr>	emploi <chr>
	9	7.48	7.25	6.46	3.47	oui	non	cdi
	11	7.28	7.47	6.97	3.56	oui	non	cdi
	14	8.42	8.01	7.83	3.47	oui	non	cdi
	16	7.47	7.59	7.53	3.78	oui	non	cdi
A data.frame: 11 × 7	28	7.63	7.77	6.79	3.66	oui	non	cdi
	29	6.18	6.40	6.30	4.08	oui	non	cdi
	30	7.57	7.53	6.63	3.43	oui	non	cdi
	32	8.03	7.94	7.29	3.78	oui	non	cdi
	35	7.92	7.92	6.82	3.66	oui	non	cdi
	39	8.78	8.58	8.69	3.78	oui	non	cdi
	47	8.17	8.29	8.23	3.95	oui	non	cdi

2. Combien de couples ont vu leur prêts refusés malgré un emploi en CDI ?

```
[29]: subset(credit, emploi == "cdi" & acceptation == "non")
```

		sal.homme <dbl>	sal.femme <dbl>	rev.tete <dbl>	age <dbl>	acceptation <chr>	garantie.supp <chr>	emploi <chr>
A data.frame: 6 × 7	43	7.48	6.96	6.85	3.37	non	hypothèque	cdi
	44	7.69	7.11	7.44	4.16	non	hypothèque	cdi
	45	7.44	7.16	6.91	3.78	non	non	cdi
	48	7.40	7.29	7.35	3.09	non	hypothèque	cdi
	49	7.26	6.81	7.06	4.16	non	non	cdi
	50	7.50	7.16	7.35	4.08	non	hypothèque	cdi

3. Représentez graphiquement les salaire des hommes du couples qui sont en CDD par rapport à ceux qui sont en CDI. Qu'en déduisez-vous ?


```
[30]: hommes_cdd = subset(credit, emploi == "cdd")$sal.homme
      hommes_cdi = subset(credit, emploi == "cdi")$sal.homme

      boxplot(hommes_cdd, hommes_cdi, xlab = "Type d'emploi", ylab = "Salaire (log)",
        ↪ names = c("CDD", "CDI"))

      mean(exp(hommes_cdi)) - mean(exp(hommes_cdd))

      # => les hommes en CDI gagnent davantage, en moyenne presque 700€ de plus que
      ↪ les hommes en CDD
```

694.172530522366



4. Représentez graphiquement les salaire des femmes du couple dont le prêt a été accepté par rapport à ceux dont le prêt a été refusé. Qu'en déduisez-vous ?

```
[31]: femmes_oui = subset(credit, acceptation == "oui")$sal.femme
      femmes_non = subset(credit, acceptation == "non")$sal.femme

      boxplot(femmes_oui, femmes_non, xlab = "Acceptation du prêt ?", ylab = "Salaire_
      ↪des femmes", names = c("Oui", "Non"))

      # => Les femmes dont le couple a vu son prêt accepté gagnaient en moyenne mieux_
      ↪leur vie que celles dont le prêt a été refusé
```

