

TD3__Intervalle__de__confiance

August 25, 2026

1 TD 3 : Intervalle de confiance

Christelle Gonindard et Matthias Grenié

1.1 Objectifs

- Comprendre la notion d'intervalle de confiance
- Identifier les conditions d'application pour calculer un intervalle de confiance
- Utiliser deux méthodes, une graphique et une statistique, pour vérifier la normalité d'échantille
- Calculer et interpréter des intervalles de confiance à l'aide d'une fonction fournie

1.2 1. Présentation des données

Un clinicien évalue l'intensité de la dépression sur l'échelle de Hamilton qui varie de 0 (non déprimé) à 56 (très déprimé), chez 100 patients souffrant d'un Episode Dépressif Majeur (EDM). On veut savoir si l'acupuncture améliore l'évolution de la dépression. Pour cela, 100 malades de même état dépressif (même score de Hamilton) sont répartis en 2 groupes de 50 par tirage au sort. Le groupe I a reçu uniquement le traitement pharmacologique et le groupe II a reçu le traitement pharmacologique associé à de l'acupuncture.

Le jeu de données contient les variables suivantes en colonne : - `hamilton_g1` : Les scores de Hamilton, après 8 mois de traitement pour le groupe 1 ; - `hamilton_g2` : Les scores de Hamilton, après 8 mois de traitement pour le groupe 2 ; - `age_g1` : l'âge des patients du groupe 1 ; - `age_g2` : l'âge des patients du groupe 2 ; - `poids_g1` : le poids des patients du groupe 1 ; - `poids_g2` : le poids des patients du groupe 2 ; - `sexe_g1` : le sexe des patients du groupe 1 ("F" : femme, "H" : homme) ; - `sexe_g2` : le sexe des patients du groupe 2 ("F" : femme, "H" : homme) ; - `urbanisation_g1` : le niveau d'urbanisation dans lequel vivent les patients du groupe 1 ("A" : rural, "B" : urbanisation modéré, "C" : fortement urbanisé) ; - `urbanisation_g2` : le niveau d'urbanisation dans lequel vivent les patients du groupe 2 ("A" : rural, "B" : urbanisation modéré, "C" : fortement urbanisé).

Les données sont contenues dans le fichier texte nommé `depression.txt` qui se trouve dans le dossier `data`. Le chemin d'accès complet du fichier est donc `data/depression.txt`.

```
[1]: depression = read.table("data/depression.txt", header = TRUE)

# Afficher le début du contenu du fichier de données
head(depression)
```

		hamilton_g1 <int>	hamilton_g2 <int>	urbanisation_g1 <chr>	urbanisation_g2 <chr>	age_g1 <int>	age_g2 <int>
A data.frame: 6 × 10	1	43	25	B	B	57	48
	2	29	29	A	B	37	41
	3	34	18	A	A	7	30
	4	39	23	A	A	37	41
	5	40	24	B	A	15	30
	6	41	25	B	B	45	45

1.3 2. Rappel de cours : Intervalle de confiance

Pourquoi calculer un intervalle de confiance ?

L'estimation a pour objectif de déterminer les valeurs inconnues des paramètres de la population (proportion, moyenne, variance) à partir des données de l'échantillon. C'est une fonction des observations de l'échantillon dont la valeur sera utilisée en lieu et place de la valeur vraie du paramètre. La valeur prise par le paramètre sur un échantillon donné est appelée une estimation. L'estimateur est une **variable aléatoire** avec une **moyenne** et une **variance**.

Lorsque l'on passe d'un échantillon à un autre, l'estimateur reste le même (par exemple la moyenne) mais sa valeur varie, comme le montre l'exemple ci-dessous sur les deux échantillons de 100 vaccins, il y a deux estimations de la fréquence de vaccins non conforme : 5% pour le groupe A et 3% pour le groupe B.

Exemple : Estimation de la fréquence de vaccins non-conformes dans deux échantillons différents A et B de la même série de vaccins.

La valeur de l'estimation fluctue en fonction de l'échantillonnage. Les méthodes d'estimation ponctuelles ne portent que sur les données d'un échantillon, or dans une population, il est possible de choisir différents échantillons :

Il est donc impossible d'obtenir la véritable valeur moyenne dans la population étudiée, on ne peut obtenir que des estimations sur des échantillons. De plus, l'estimation d'une moyenne à partir d'un échantillon ne présente pas grand intérêt si on n'a aucune idée de la précision de l'estimation obtenue. Aussi, on est conduit à rechercher un intervalle dans lequel il y a de bonnes chances que se trouve la vraie valeur de la moyenne. On procède alors à une estimation par intervalle de confiance à un niveau de confiance que l'on se fixe $(1 - \alpha)\%$.

$$IC_{(1-\alpha)\%} = [\text{Borne}_{\text{inférieure}} ; \text{Borne}_{\text{supérieure}}]$$

Les bornes de l'intervalle de confiance dépendent de l'échantillon étudié. Une infinité d'intervalles de confiance peuvent être calculés à partir d'une infinité d'échantillons.

Note importante sur l'interprétation d'un intervalle de confiance : un intervalle de confiance à $X\%$ ne signifie pas que l'intervalle va réellement contenir la vraie valeur de la moyenne $X\%$ du temps mais que si l'on prenait 100 échantillons de la même population et que l'on construisait 100 intervalles de confiance, alors $X\%$ d'entre eux contiendraient la vraie valeur de la moyenne.

1.4 3. Calcul de l'intervalle de confiance

Question du TD : Quel est l'intervalle de confiance de la moyenne des scores de Hamilton du groupe 1 pour les individus de sexe féminin ?

1.4.1 3.1 Construction du jeu de données qui permet de répondre à la question

La réponse à cette question demande en premier : - de construire un jeu de données contenant l'ensemble des scores de Hamilton du groupe 1 pour les individus de sexe féminin. - d'afficher la taille de l'échantillon (on peut utiliser la fonction `length()`, longueur en Anglais pour obtenir la taille de l'échantillon, */!\ cela s'écrit **lenGTH** et pas **lenTGH** ou autre variation* */!*) - de tracer l'histogramme de ces scores - de tracer le boxplot de ces scores

```
[2]: # Extraction des données
femme_g1 <- depression$hamilton_g1[depression$sexe_g1 == "F"]

# Affichage des données extraites
femme_g1

# taille de l'échantillon
length(femme_g1)


# tracer l'histogramme
hist(femme_g1, main = "Femmes groupe 1", xlab = "Score de Hamilton")


# tracer du boxplot
boxplot(femme_g1, main = "Femmes groupe 1", ylab = "Score de Hamilton")
```

1. 43 2. 37 3. 38 4. 40 5. 37 6. 41 7. 43 8. 47 9. 46 10. 42 11. 44

11

Femmes groupe 1





1.4.2 3.2 Calcul des paramètres de l'échantillon

Décrire l'échantillon en calculant : - la moyenne - la variance - l'écart type - afficher le résumé statistique

Commenter vos résultats

```
[3]: mean(femme_g1)
var(femme_g1)
sd(femme_g1)
summary(femme_g1)
```

41.6363636363636

11.6545454545455

3.41387543043759

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
37.00	39.00	42.00	41.64	43.50	47.00

Commentaire :

La moyenne du score de Hamilton des femmes du groupes G1 est de 41.6, elle a été obtenue à partir d'un petit échantillonnage de seulement 11 patientes avec un écart-type d'environ 3.5 année. Cette estimation de la moyenne ne représente donc pas la valeur exacte du score de Hamilton pour toutes les femmes qui auraient reçu le traitement mais seulement une estimation. Si nous échantillonnons dans les mêmes conditions un autre groupe de femmes, la valeur de la moyenne changerait sensiblement. Il est donc important de calculer l'intervalle de confiance afin d'avoir une idée bornes entre lesquelles se situe la moyenne théorique en fixant notre seul d'erreur.

Conditions d'application : - Si la taille de l'échantillon est grande ($n \geq 30$) : pas de condition d'application -> on peut calculer l'intervalle de confiance - Si la taille de l'échantillon est petite ($n < 30$) : il faut que les données suivent une loi normale


1.4.3 3.3 Vérification de la Normalité de l'échantillon

Méthode graphique : diagramme quantile-quantile Une méthode graphique permet de vérifier cette normalité en traçant les quantiles de l'échantillon en fonction des quantiles d'une loi normale. L'idée est de calculer les quantiles théoriques qu'auraient une loi normale de même moyenne et de même écart-type que les données observées, on les compare aux quantiles observés. Sous l'hypothèse de normalité les points doivent s'aligner sur une droite. Si les points sont proches d'une droite, notre distribution observée suit donc une loi normale.

Sur R, pour faire un diagramme quantile-quantile de loi Normale on doit d'abord utiliser la fonction `qqnorm()` sur le vecteur de données (pour ***quantile-quantile of a normal distribution**), puis `qqline()` sur le même vecteur pour obtenir la ligne droite.

Représentez le diagramme quantile-quantile pour les scores de Hamilton des femmes du groupe 1

```
[4]: qqnorm(femme_g1)
      qqline(femme_g1)
```



Interprétation :

Globalement les quantiles observés de l'échantillon (points) s'alignent bien avec la droite des quantiles théoriques de la loi normale. Il semblerait que les données suivent bien une loi normale. Si ils ne s'alignent pas parfaitement c'est dû à plusieurs facteurs : la faible taille des échantillonnages, la variabilité des données...

Test de Normalité Il est aussi possible d'avoir une approche basée sur un test numérique, par exemple en calculant la variable W du test de Shapiro-Wilk. Ce test statistique permet de vérifier la normalité d'une échantillon en calculant la valeur W et en la comparant à une valeur théorique. Si la valeur observée est proche de la valeur théorique attendue, alors on conclura que notre distribution suit une loi Normale, si on observe un grand écart, alors on conclura que notre échantillon ne suit pas une loi normale.

Voici les hypothèses de Shapiro-Wilk :

Hypothèse nulle (notée H0) : la distribution de notre échantillon suit une loi normale.

Hypothèse alternative (notée H1) : la distribution de notre échantillon ne suit pas une loi normale.

Pour réaliser ce test sur R, il faut utiliser la fonction `shapiro.test()` qui prend comme argument le vecteur de valeurs de l'échantillon à tester.

```
[5]: shapiro.test(femme_g1)
```

Shapiro-Wilk normality test

data: femme_g1

W = 0.94764, p-value = 0.614

Conclusion :

On observe que $p = 0.61 > \alpha = 0.05$, donc on ne peut pas rejeter l'hypothèse H0 donc la distribution des scores de Hamilton des femmes du groupe 1 suit une loi normale.

Et donc, les conditions d'application pour calculer un intervalle de confiance sont vérifiées, on peut le calculer.

1.4.4 3.4 Calcul de l'intervalle de confiance

La moyenne m que nous avons calculée à partir de notre échantillon est une estimation de la moyenne μ du score de Hamilton de la population des femmes du groupe 1. m fluctue en fonction de l'échantillon que nous analysons (= si l'on choisissait un autre échantillon, on obtiendrait une autre valeur de m). C'est donc une variable aléatoire se distribuant selon une loi normale d'espérance $E[m]$ et de variance $V[m]$ si le score de Hamilton se distribue lui même selon une loi normale avec une moyenne μ et une variance σ^2 .

Pour un échantillon de taille n et pour un intervalle de confiance à un seuil α donnée (souvent 95%) se calcule avec la formule suivante :

$$IC = \mu \pm Z\left(1 - \frac{\alpha}{2}\right) \frac{\sigma}{\sqrt{n}}$$

avec $Z\left(1 - \frac{\alpha}{2}\right)$ le quantile de la loi de Student d'ordre $1 - \frac{\alpha}{2}$ de la loi de Student à $n - 1$ degrés de liberté.

Il n'existe pas de fonction en **R** permettant de calculer directement un intervalle de confiance. Comme ce calcul nécessite plusieurs opérations nous vous proposons une fonction créée pour l'occasion s'appelant `CI()` (pour *Confidence Interval*, intervalle de confiance en anglais) vous permettant de le faire en une simple ligne. La fonction comme premier argument le vecteur contenant les valeurs sur lesquelles calculer l'intervalle de confiance, en deuxième argument elle prend le pourcentage de confiance associée à l'intervalle, par exemple 0.95 pour un intervalle à 95%.

Vous devez exécuter le bloc de code ci-dessous avant de pouvoir vous servir de la fonction.

Il faudra rajouter cette fonction au début de chaque nouveau TD pour vous en servir.

```
[6]: CI <- function(x, confidence){
  alpha = 1 - confidence
  mu = mean(x)
  sigma = sd(x)
  n = length(x)
  CI_inf = mu - (qt(1 - alpha/2, n-1) * sigma/sqrt(n))
  CI_sup = mu + (qt(1 - alpha/2, n-1) * sigma/sqrt(n))
  CI = c(inf = CI_inf, sup = CI_sup)
  return(CI)
}
```

On peut maintenant utiliser la fonction sur notre série de données

```
[7]: # Intervalle de confiance donné par défaut à 95%
CI(femme_g1, 0.95)
```

```
inf                39.3428909153857 sup                43.9298363573416
```

Interprétation :

La vraie moyenne se situe donc entre les bornes 39 et 44 au seuil 95%

Application : calculer l'intervalle de confiance à 98% du score hamilton des femmes du groupe 1

```
[8]: # Intervalle de confiance pour modifier le seuil
CI(femme_g1, 0.98)
```

```
inf                38.7915544568985 sup                44.4811728158288
```

Interprétation :

Cette fois, les bornes de l'intervalle de confiance sont : 38 et 45 au seuil 98%.

1.5 En résumé

Dans cette séance :

- Nous avons rappelé la théorie des intervalles de confiance
- Nous avons rappelé les conditions d'application à vérifier avant de les calculer : si $n \geq 30$ pas de conditions à vérifier, sinon il faut vérifier la normalité de l'échantillon
- Nous avons appris à utiliser deux méthodes pour vérifier la normalité d'un échantillon : (1) la méthode graphique avec le diagramme quantile-quantile avec `qqnorm()` et `qqline()`, (2) la méthode statistique avec le test de Shapiro-Wilk en utilisant `shapiro.test()`
- Nous avons appris à interpréter les résultats d'un test statistique en utilisant les p-values et à conclure sur les hypothèses
- Nous avons vu comment calculer un intervalle de confiance avec la fonction particulière `CI()` et comment l'interpréter

1.6 4. Exercices d'application

1.6.1 4.1 Exercices d'entraînement (à faire en cours si possible)

Exercice 1

1. Calculer l'intervalle de confiance du score de Hamilton des hommes puis des femmes pour le groupe 1, en vérifiant les conditions d'application (au seuil 95%)
2. Calculer l'intervalle de confiance du score de Hamilton des hommes puis des femmes pour le groupe 2, en vérifiant ces conditions d'application (au seuil 95%)
3. Qu'en concluez-vous ?

```
[9]: # Question 1 : Calculer l'intervalle de confiance du score de Hamilton des_
      ↪hommes
      # puis des femmes pour le groupe 1, en vérifiant les conditions d'application_
      ↪(au seuil 95%)

      # femme déjà fait précédemment
      # IC femme G1 = 39 et 44 au seuil 95%

      # homme
      homme_g1 = depression$hamilton_g1[depression$sexe_g1 == "H"]

      length(homme_g1)

      ## pas de condition d'application

      CI(homme_g1, 0.95)

      # IC homme G1 = 36 et 40 au seuil 95%

      # Question 2 : Calculer l'intervalle de confiance du score de Hamilton des_
      ↪hommes puis des femmes
      # pour le groupe 2, en vérifiant ces conditions d'application (au seuil 95%)

      # femme
      femme_g2 = depression$hamilton_g2[depression$sexe_g2=="F"]

      length(femme_g2)

      shapiro.test(femme_g2)

      CI(femme_g2,0.95)

      # IC femme G1 = 18 et 31 au seuil 95%

      # homme
```

```
homme_g2=depression$hamilton_g2[depression$sexe_g2=="H"]
```

```
length(homme_g2)
```

```
## pas de condition d'application
```

```
CI(homme_g2,0.95)
```

```
# IC homme G1 = 23 et 27 au seuil 95%
```

39

inf	36.3595508838125	sup	39.5891670649054
-----	------------------	-----	------------------

5

Shapiro-Wilk normality test

data: femme_g2

W = 0.96258, p-value = 0.8258

inf	18.0332160011029	sup	31.5667839988971
-----	------------------	-----	------------------

45

inf	23.0026458856954	sup	26.0195763365269
-----	------------------	-----	------------------

Rapidement : - Groupe 2 moins dépressif aussi bien chez les hommes que les femmes, ce qui laisserait penser que l'acupuncture a un effet bénéfique - Dans groupe 1 : homme moins dépressif que les femmes, dans le groupe 2 niveau dépression équilibré (attention aux faibles échantillonnages qui agrandit les bornes de l'IC).

Exercice 2

1. Extraire un sous jeu de données que l'on nommera U1 et qui contient les score de Hamilton du groupe 1 dans les zones faiblement urbanisées (c'est-à-dire `urbanisation_g1 == "A"`)
2. Calculer l'intervalle de confiance de U1, en vérifiant les conditions d'application (au seuil 95%)
3. Extraire un sous jeu de données que l'on nommera U2 et qui contient les score de Hamilton du groupe 1 dans les zones urbanisées (c'est-à-dire `urbanisation_g1 == "B"`)
4. Calculer l'intervalle de confiance de U2, en vérifiant les conditions d'application (au seuil 95%)
5. Qu'en concluez-vous ?

```
[10]: # 1. Extraire un sous jeu de données que l'on nommera U1 et qui contient les
      ↪ score de Hamilton du groupe 1
      # dans les zones faiblement urbanisées (c'est-à-dire urbanisation_g1=="A")
```

```
U1=depression$hamilton_g1[depression$urbanisation_g1=="A"]
```

```

# 2. Calculer l'intervalle de confiance de U1, en vérifiant les conditions
↳ d'application (au seuil 95%)

length(U1)

# n < 30 => condition d'application

shapiro.test(U1)

CI(U1,0.95)

# 3. Extraire un sous jeu de données que l'on nommera U2 et qui contient les
↳ score de Hamilton du groupe
# 1 dans les zones urbanisées (c'est-à-dire urbanisation_g1=="B")

U2=depression$hamilton_g1[depression$urbanisation_g1=="B"]

# 4. Calculer l'intervalle de confiance de U2, en vérifiant les conditions
↳ d'application (au seuil 95%)

length(U2)

# n < 30 => condition d'application

shapiro.test(U2)

# On ne peut pas calculer l'intervalle de confiance au seuil 5%

```

24

Shapiro-Wilk normality test

data: U1

W = 0.94213, p-value = 0.182

inf 33.2903840184366 sup 35.6262826482301

21

Shapiro-Wilk normality test

data: U2

W = 0.88686, p-value = 0.01962

1.6.2 4.2 Exercices supplémentaires

Ces exercices vous permettent de réviser les deux premiers TD.

Exercice A

1. Extraire tableau de données que l'on nommera `g2_b` et qui contient les informations relatives au groupe 2 dans les zones urbanisées (c'est-à-dire `urbanisation_g2 == "B"`).
2. Retirer de ce jeu de donnée l'individu le plus âgé. (*indice pour ce faire, il faut d'abord trouver la valeur maximum du poids, puis enlever cette valeur à partir des filtres*)
3. À partir de ce tableau `g2_b`, calculez la moyenne, la médiane, les quartiles et l'écart type du poids.
4. Extraire un sous-jeu de données que l'on nommera `g2_a` et qui contient les scores de Hamilton du groupe 2 dans les zones urbanisées (c'est-à-dire `urbanisation_g2 == "A"`).
5. Retirer de ce jeu de donnée la femme la plus légère. (*même indice que la question 2*)
6. A partir du tableau `g2_a`, calculez la moyenne, les quartiles et la variance de l'âge.
7. Pour `g2_b` et `g2_a`, calculez les intervalles de confiances du score Hamilton, en vérifiant les conditions d'application (au seuil 95%)
8. Qu'en concluez-vous ?

```
[11]: #1. Extraire tableau de données que l'on nommera U3 et qui contient les_
      ↪ informations relatives au groupe 2
      # dans les zones urbanisées (c'est-à-dire urbanisation_g2=="B").
```

```
g2_b =depression[depression$urbanisation_g2=="B",c(2,4,6,8,10)]
```

```
head(g2_b)
```

```
dim(g2_b)
```

```
#2. Retirer de ce jeu de donnée l'individu le plus âgé.
```

```
summary(g2_b)
```

```
g2_b = subset(g2_b, age_g2 != max(g2_b$age_g2))
```

```
dim(g2_b)
```

		hamilton_g2	urbanisation_g2	age_g2	poids_g2	sexe_g2
		<int>	<chr>	<int>	<int>	<chr>
A data.frame: 6 × 5	1	25	B	48	93	H
	2	29	B	41	92	H
	6	25	B	45	98	H
	7	27	B	41	75	H
	9	27	B	47	83	H
	13	26	B	29	85	H

1. 26 2. 5

hاملton_g2	urbanisation_g2	age_g2	poids_g2
Min. :25.00	Length:26	Min. :13.00	Min. : 74.00
1st Qu.:26.00	Class :character	1st Qu.:30.25	1st Qu.: 80.75
Median :28.00	Mode :character	Median :39.50	Median : 86.00
Mean :28.38		Mean :37.77	Mean : 86.85
3rd Qu.:30.00		3rd Qu.:46.00	3rd Qu.: 92.00
Max. :36.00		Max. :55.00	Max. :106.00

sexe_g2
Length:26
Class :character
Mode :character

1. 25 2. 5

[12]: *#3. A partir de ce tableau U3, calculez la moyenne, la médiane, les quartiles et l'écart type du poids.*

```
summary(g2_b$poids_g2)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
74.00	80.00	86.00	86.92	92.00	106.00

[13]: *#4. Extraire tableau de données que l'on nommera U4 et qui contient les informations relatives au groupe 2 dans les zones urbanisées (c'est-à-dire urbanisation_g2=="A").*

```
g2_a=depression[depression$urbanisation_g2 == "A", c(2,4,6,8,10)]
```

```
head(g2_a)
```

```
dim(g2_a)
```

```
summary(g2_a)
```

#5. Retirer de ce jeu de données la femme la plus légère.

```
summary(g2_a$poids_g2[g2_a$sexe_g2 == "F"])
```

```
poids_min_femme=min(g2_a$poids_g2[g2_a$sexe_g2 == "F"])
```

```
poids_min_femme
```

```
g2_a = g2_a[g2_a$poids_g2 > poids_min_femme,]
```

```
dim(g2_a)
```

```
summary(g2_a)
```

		hاملton_g2 <int>	urbanisation_g2 <chr>	age_g2 <int>	poids_g2 <int>	sexe_g2 <chr>
A data.frame: 6 × 5	3	18	A	30	86	H
	4	23	A	41	81	H
	5	24	A	30	74	F
	8	16	A	17	90	H
	10	16	A	48	82	H
	11	18	A	29	66	F

1. 24 2. 5

hاملton_g2	urbanisation_g2	age_g2	poids_g2
Min. :15.00	Length:24	Min. :17.00	Min. : 66.00
1st Qu.:18.00	Class :character	1st Qu.:30.00	1st Qu.: 80.50
Median :20.00	Mode :character	Median :35.00	Median : 84.50
Mean :20.38		Mean :35.92	Mean : 85.96
3rd Qu.:23.25		3rd Qu.:41.75	3rd Qu.: 91.75
Max. :24.00		Max. :55.00	Max. :104.00

sexe_g2
Length:24
Class :character
Mode :character

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
66.0	69.5	73.0	71.0	73.5	74.0

66

1. 23 2. 5

hاملton_g2	urbanisation_g2	age_g2	poids_g2
Min. :15.00	Length:23	Min. :17.00	Min. : 73.00
1st Qu.:18.50	Class :character	1st Qu.:30.50	1st Qu.: 81.50
Median :20.00	Mode :character	Median :35.00	Median : 85.00
Mean :20.48		Mean :36.22	Mean : 86.83
3rd Qu.:23.50		3rd Qu.:42.50	3rd Qu.: 92.50
Max. :24.00		Max. :55.00	Max. :104.00

sexe_g2
Length:23
Class :character
Mode :character

```
[14]: #6. A partir du tableau U4, calculez la moyenne, les quartiles et la variance
      ↪ de l'âge.

summary(g2_a$age_g2)

#7. Pour U3 et U4, calculez les intervalles de confiances du score Hamilton, en
      ↪ vérifiant les conditions
# d'application (au seuil 95%)

nrow(g2_b)

length(g2_a)

# n < 30

shapiro.test(g2_b$hamilton_g2)
shapiro.test(g2_a$hamilton_g2)

# normalité pour h_3 mais pas pour h_4 => on peut calculer que l'IC de h_3

CI(g2_b$hamilton_g2, 0.85)

#8. Qu'en concluez-vous ?
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
17.00	30.50	35.00	36.22	42.50	55.00

25

5

Shapiro-Wilk normality test

data: g2_b\$hamilton_g2

W = 0.92616, p-value = 0.07088

Shapiro-Wilk normality test

data: g2_a\$hamilton_g2

W = 0.87583, p-value = 0.008301

inf	27.6870269406205	sup	29.3529730593795
-----	------------------	-----	------------------

Exercice B

1. Qu'elle est l'âge maximum et minimum de la femme appartenant au groupe 1 dans les zones urbanisées et dont le poids est strictement inférieur au deuxième quartile.
2. Même question pour le groupe 2 dans les zones faiblement urbanisées et dont le poids le poids et supérieur ou égale au 8ème décile (un décile est un quantile à 10%, on peut le calculer avec la fonction `quantile(x, 0.8)`).
3. Représenter graphiquement l'âge en fonction du poids pour les individus du groupe 2.
(indice vous pouvez le faire en utilisant la fonction `plot()` en précisant d'abord la variable de coordonnées sur l'axe des abscisses, puis celle sur l'axe des ordonnées)
4. Représenter graphiquement l'âge en fonction du poids pour les hommes du groupe 1.
5. Représenter graphiquement les boxplots représentant les âges dans les groupes 1 et 2 en séparant les hommes et les femmes.
6. Représenter graphiquement les boxplots représentant les poids dans les groupes 1 et 2 en séparant les hommes et les femmes.

Pensez à commenter vos graphiques

```
[15]: #1. Qu'elle est l'âge maximum et minimum de la femme appartenant au groupe 1
      ↪ dans les zones modérément
      # urbanisées et dont le poids est strictement inférieur au deuxième quartile.

      z = depression$age_g1[
        depression$sexe_g1 == "F" &
        depression$urbanisation_g1 == "B" &
        depression$poids_g1 < median(depression$poids_g1)
      ]

      z

      #2. Même question pour le groupe 2 dans les zones faiblement urbanisées et dont
      ↪ le poids le poids
      # et supérieur ou égale au 7 déciles.

      z2=depression$age_g2[
        depression$sexe_g2 == "F" &
        depression$urbanisation_g2 == "B" &
        depression$poids_g2 >= quantile(depression$poids_g2, 0.8)
      ]

      z2

      #3. Représenter graphiquement l'âge en fonction du poids pour les individus du
      ↪ groupe 2.

      plot(depression$poids_g2,depression$age_g2)

      #4. Représenter graphiquement l'âge en fonction du poids pour les hommes du
      ↪ groupe 1.
      plot(depression$poids_g1,depression$age_g1)
```

#5. Représenter graphiquement les boxplots représentant les âges dans les ↵
 ↪groupes 1 et 2 en séparant les hommes et les femmes.

```
boxplot(depression$age_g1~depression$sexe_g1)
```


```
boxplot(depression$age_g2~depression$sexe_g2)
```


#6. Représenter graphiquement les boxplots représentant les poids dans les ↵
 ↪groupes 1 et 2 en séparant les hommes et les femmes.


```
boxplot(depression$poids_g1~depression$sexe_g1)
```


```
boxplot(depression$poids_g2~depression$sexe_g2)
```


1. 57 2. 62 3. 56 4. 40 5. 72 6. 23














Exercice C On souhaite ici calculer des intervalles à 98%, le risque α pour le test est de 1%

1. reprenez les exercices 1 et 2 en calculant l'intervalle de confiance de l'âge.
2. reprenez les exercices 1 et 2 en calculant l'intervalle de confiance du poids.

I. Intervalles de confiances sur les données âges

```
[16]: ##### Exercice 1

# Question 1 : Calculer l'intervalle de confiance des âges des hommes
# puis des femmes pour le groupe 1, en vérifiant les conditions d'application
# (au seuil 95%)
```

```

# femme
femme_g1=depression$age_g1[depression$sexe_g1 == "F"]

length(femme_g1)

shapiro.test(femme_g1)

CI(femme_g1, 0.98)

# homme
homme_g1=depression$age_g1[depression$sexe_g1 == "H"]

length(homme_g1)

## pas de condition d'application

CI(homme_g1, 0.98)

# IC homme G1 = 36 et 40 au seuil 95%

# Question 2 : Calculer l'intervalle de confiance du score de Hamilton des
↳hommes puis des femmes
# pour le groupe 2, en vérifiant ces conditions d'application (au seuil 95%)

# femme
femme_g2=depression$age_g2[depression$sexe_g2 == "F"]

length(femme_g2)

shapiro.test(femme_g2)

CI(femme_g2,0.98)

# IC femme G1 = 18 et 31 au seuil 95%

# homme
homme_g2=depression$age_g2[depression$sexe_g2 == "H"]

length(homme_g2)

## pas de condition d'application

CI(homme_g2,0.98)

# IC homme G1 = 23 et 27 au seuil 95%

```

11

Shapiro-Wilk normality test

data: femme_g1

W = 0.97582, p-value = 0.9385

inf 37.3005670451596 sup 59.4267056821132

39

inf 34.0467005481983 sup 42.3122738107761

5

Shapiro-Wilk normality test

data: femme_g2

W = 0.77106, p-value = 0.04609

inf 26.8501102129347 sup 41.9498897870653

45

inf 33.3772616900662 sup 40.9338494210449

[17]: ##### Exercice 2 :

```
# 1. Extraire un sous jeu de données que l'on nommera U1 et qui contient les
↳ âges du groupe 1
# dans les zones faiblement urbanisées (c'est-à-dire urbanisation_g1=="A")

U1=depression$age_g1[depression$urbanisation_g1=="A"]

# 2. Calculer l'intervalle de confiance de U1, en vérifiant les conditions
↳ d'application (au seuil 95%)

length(U1)

# n < 30 => condition d'application

shapiro.test(U1)

# => On ne peut pas calculer l'IC

# 3. Extraire un sous jeu de données que l'on nommera U2 et qui contient les
↳ score de Hamilton du groupe
# 1 dans les zones urbanisées (c'est-à-dire urbanisation_g1=="B")
```

```

U2=depression$age_g1[depression$urbanisation_g1=="B"]

# 4. Calculer l'intervalle de confiance de U2, en vérifiant les conditions
↳ d'application (au seuil 95%)

length(U2)

# n < 30 => condition d'application

shapiro.test(U2)

CI(U2,0.95)

```

24

Shapiro-Wilk normality test

data: U1
W = 0.82357, p-value = 0.0007341

21

Shapiro-Wilk normality test

data: U2
W = 0.97419, p-value = 0.8228

inf 34.4034063628295 sup 47.0251650657419

II. Intervalles de confiances sur les données poids

```

[18]: ##### Intervalles de confiance sur les données poids

# Exercice 1

# Question 1 : Calculer l'intervalle de confiance des âges des hommes
# puis des femmes pour le groupe 1, en vérifiant les conditions d'application
↳ (au seuil 95%)

# femme
femme_g1=depression$poids_g1[depression$sexe_g1=="F"]

length(femme_g1)

```

```

shapiro.test(femme_g1)

CI(femme_g1,0.98)

# homme
homme_g1=depression$poids_g1[depression$sexe_g1=="H"]

length(homme_g1)

## pas de condition d'application

CI(homme_g1,0.98)

# IC homme G1 = 36 et 40 au seuil 95%

# Question 2 : Calculer l'intervalle de confiance du score de Hamilton des
  ↪hommes puis des femmes
# pour le groupe 2, en vérifiant ces conditions d'application (au seuil 95%)

# femme
femme_g2=depression$poids_g2[depression$sexe_g2=="F"]

length(femme_g2)

shapiro.test(femme_g2)

# on ne peut pas calculer l'IC

# homme
homme_g2=depression$poids_g2[depression$sexe_g2=="H"]

length(homme_g2)

## pas de condition d'application

CI(homme_g2,0.98)

# IC homme G1 = 23 et 27 au seuil 95%

```

11

Shapiro-Wilk normality test

data: femme_g1

W = 0.87808, p-value = 0.09837

```

inf          67.9007387547752 sup          73.1901703361339
39
inf          83.8076867858388 sup          90.6025696244176
5

```

Shapiro-Wilk normality test

```

data:  femme_g2
W = 0.63313, p-value = 0.001667

```

45

```

inf          85.1301929460107 sup          90.8698070539893

```

```

[19]: ##### Exercice 2 :

# 1. Extraire un sous jeu de données que l'on nommera U1 et qui contient les
#      ↪ poids du groupe 1
# dans les zones faiblement urbanisées (c'est-à-dire urbanisation_g1=="A")

U1=depression$poids_g1[depression$urbanisation_g1=="A"]

# 2. Calculer l'intervalle de confiance de U1, en vérifiant les conditions
#      ↪ d'application (au seuil 95%)

length(U1)

# n < 30 => condition d'application

CI(U1,0.95)

# 3. Extraire un sous jeu de données que l'on nommera U2 et qui contient les
#      ↪ score de Hamilton du groupe
# 1 dans les zones urbanisées (c'est-à-dire urbanisation_g1=="B")

U2=depression$poids_g1[depression$urbanisation_g1=="B"]

# 4. Calculer l'intervalle de confiance de U2, en vérifiant les conditions
#      ↪ d'application (au seuil 95%)

length(U2)

```

```
# n < 30 => condition d'application
```

```
shapiro.test(U2)
```

```
CI(U2,0.95)
```

24

inf 80.5359035175452 sup 89.2140964824548

21

Shapiro-Wilk normality test

data: U2

W = 0.9631, p-value = 0.5806

inf 77.0501182724572 sup 86.1879769656381

Exercice D Exécuter le bloc de code ci-dessous pour créer un nouveau tableau `depression_long` à partir du fichier `depression_long.txt` dans le dossier `data/`. **Vous n'avez pas à le comprendre.** Il s'agit des mêmes données que celles du fichier `depression.txt` mais présentées sous un autre format.

Ce nouveau tableau contient les colonnes suivantes : - groupe - hamilton - urbanisation - age - poids - sexe

```
[20]: depression_long = read.table("data/depression_long.txt",h=T)
```

```
head(depression_long)
```

A data.frame: 6 × 6

		groupe <chr>	hamilton <int>	urbanisation <chr>	age <int>	poids <int>	sexe <chr>
1	G1	43	B	57	74	F	
2	G2	25	B	48	93	H	
3	G1	29	A	37	95	H	
4	G2	29	B	41	92	H	
5	G1	34	A	7	84	H	
6	G2	18	A	30	86	H	

En utilisant ce nouveau tableau, pour l'âge des hommes et des femmes :

1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.
2. Représenter graphiquement ces 2 groupes.
3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.
4. Qu'en concluez-vous ?

```
[21]: # 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.
```

```

age_homme=depression_long$age[depression_long$sexe=="H"]
age_femme=depression_long$age[depression_long$sexe=="F"]

length(age_homme)
length(age_femme)

# Statistique concernant les hommes
mean(age_homme)
median(age_homme)
sd(age_homme)
quantile(age_homme,0.25)
quantile(age_homme,0.75)

# Statistique concernant les femmes
mean(age_femme)
median(age_femme)
sd(age_femme)
quantile(age_femme,0.25)
quantile(age_femme,0.75)

# 2. Représenter graphiquement ces 2 groupes.
boxplot(depression_long$age~depression_long$sexe)

# 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.

##### Hommes

## IC hommes n> 30 pas de condition

### IC à 95%

CI(age_homme,0.95)

### IC à 98%
CI(age_homme,0.98)

##### Femmes

## IC femmes n< 30 condition

shapiro.test(age_femme)

### IC à 95%

CI(age_femme,0.95)

```

```
### IC à 98%  
CI(age_femme,0.98)
```

```
# 4. Qu'en concluez-vous ?
```

84

16

37.6309523809524

39

10.5073465543001

25\%: 31

75\%: 45.25

44

41

12.9460418661458

25\%: 37.75

75\%: 53

inf 35.3507183942155 **sup**

39.9111863676892

inf 34.9114476656828 **sup**

40.350457096222

Shapiro-Wilk normality test

data: age_femme


W = 0.96236, p-value = 0.7048

inf 37.1015412369014 **sup**

50.8984587630986

inf 35.5770452862416 **sup**

52.4229547137584



En utilisant ce nouveau tableau, pour l'âge des 2 groupes d'urbanisation :

1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.
2. Représenter graphiquement ces 2 groupes.
3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.
4. Qu'en concluez-vous ?

[22]: *# 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.*

```
age_A=depression_long$age[depression_long$urbanisation=="A"]
age_B=depression_long$age[depression_long$urbanisation=="B"]

length(age_B)
```

```

length(age_A)

# Statistique concernant les A
mean(age_A)
median(age_A)
sd(age_A)
quantile(age_A,0.25)
quantile(age_A,0.75)

# Statistique concernant les B
mean(age_B)
median(age_B)
sd(age_B)
quantile(age_B,0.25)
quantile(age_B,0.75)

# 2. Représenter graphiquement ces 2 groupes.
boxplot(depression_long$age[depression_long$urbanisation!
  ↪="C"]~depression_long$urbanisation[depression_long$urbanisation!="C"])

# 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.

##### Hommes

## IC A n> 30 pas de condition

### IC à 95%

CI(age_A,0.95)

### IC à 98%
CI(age_A,0.98)

##### B

## IC femmes n > 30 pas de condition

### IC à 95%

CI(age_B,0.95)

### IC à 98%
CI(age_B,0.98)

# 4. Qu'en concluez-vous ?

```

48

37.66666666666667

38

10.2403734417721

25\%: 33

75\%: 45

39.0851063829787

41

11.9397578215081

25\%: 30


75\%: 46

inf	34.6931721769971 sup	40.6401611563362
------------	-----------------------------	------------------

inf	34.1069626751018 sup	41.2263706582315
------------	-----------------------------	------------------

inf	35.5794621561428 sup	42.5907506098147
------------	-----------------------------	------------------

inf	34.8875404537905 sup	43.282672312167
------------	-----------------------------	-----------------



En utilisant ce nouveau tableau, pour le score Hamilton des hommes et des femmes :

1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.
2. Représenter graphiquement ces 2 groupes.
3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.
4. Qu'en concluez-vous ?

[23]: # 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.

```

hamilton_homme=depression_long$hamilton[depression_long$sexe=="H"]
hamilton_femme=depression_long$hamilton[depression_long$sexe=="F"]

length(hamilton_homme)

```

```

length(hamilton_femme)

# Statistique concernant les hommes
mean(hamilton_homme)
median(hamilton_homme)
sd(hamilton_homme)
quantile(hamilton_homme,0.25)
quantile(hamilton_homme,0.75)

# Statistique concernant les femmes
mean(hamilton_femme)
median(hamilton_femme)
sd(hamilton_femme)
quantile(hamilton_femme,0.25)
quantile(hamilton_femme,0.75)

# 2. Représenter graphiquement ces 2 groupes.
boxplot(depression_long$hamilton~depression_long$sexe)

# 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.

##### Hommes

## IC hommes n> 30 pas de condition

### IC à 95%

CI(hamilton_homme,0.95)

### IC à 98%
CI(hamilton_homme,0.98)

##### Femmes

## IC femmes n< 30 condition

shapiro.test(hamilton_femme)

### IC à 95%

CI(hamilton_femme,0.95)

### IC à 98%
CI(hamilton_femme,0.98)

# 4. Qu'en concluez-vous ?

```

16

30.7619047619048

30

8.38762577894889

25\%: 24.75

75\%: 37

36.375

39

8.98053450525079

25\%: 31.25

75\%: 43

inf 28.9416783831182 **sup**

32.5821311406913

inf 28.5910248220561 **sup**

32.9327847017534

Shapiro-Wilk normality test

data: hamilton_femme


W = 0.88892, p-value = 0.05356

inf 31.5896109524748 **sup**

41.1603890475252

inf 30.5320839778543 **sup**

42.2179160221457



En utilisant ce nouveau tableau, pour le score Hamilton des 2 groupes d'urbanisation :

1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.
2. Représenter graphiquement ces 2 groupes.
3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.
4. Qu'en concluez-vous ?

[24]: *# 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.*

```
hamilton_A=depression_long$hamilton[depression_long$urbanisation=="A"]
hamilton_B=depression_long$hamilton[depression_long$urbanisation=="B"]

length(hamilton_A)
```

```

length(hamilton_B)

# Statistique concernant les A
mean(hamilton_A)
median(hamilton_A)
sd(hamilton_A)
quantile(hamilton_A,0.25)
quantile(hamilton_A,0.75)

# Statistique concernant les B
mean(hamilton_B)
median(hamilton_B)
sd(hamilton_B)
quantile(hamilton_B,0.25)
quantile(hamilton_B,0.75)

# 2. Représenter graphiquement ces 2 groupes.
boxplot(depression_long$hamilton[depression_long$urbanisation!
  ↪="C"]~depression_long$urbanisation[depression_long$urbanisation!="C"])

# 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.

##### A

## IC hommes n> 30 pas de condition

### IC à 95%

CI(hamilton_A,0.95)

### IC à 98%
CI(hamilton_A,0.98)

##### B

## IC femmes n> 30 pas de condition

### IC à 95%

CI(hamilton_B,0.95)

### IC à 98%
CI(hamilton_B,0.98)

# 4. Qu'en concluez-vous ?

```

47

27.4166666666667

26.5

7.69590477816676

25\%: 20

75\%: 35

34.4255319148936


33

7.17406161368877

25\%: 27.5

75\%: 41.5

inf	25.1820088603845 sup	29.6513244729488
inf	24.7414572992237 sup	30.0918760341097
inf	32.3191485145796 sup	36.5319153152076
inf	31.9034039912207 sup	36.9476598385665



En utilisant ce nouveau tableau, pour le poids des hommes et des femmes : 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes. 2. Représenter graphiquement ces 2 groupes. 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%. 4. Qu'en concluez-vous ?

[25]: # 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.

```
poids_homme=depression_long$poids[depression_long$sexe=="H"]
poids_femme=depression_long$poids[depression_long$sexe=="F"]

length(poids_homme)
length(poids_femme)
```

```

# Statistique concernant les hommes
mean(poids_homme)
median(poids_homme)
sd(poids_homme)
quantile(poids_homme,0.25)
quantile(poids_homme,0.75)

# Statistique concernant les femmes
mean(poids_femme)
median(poids_femme)
sd(poids_femme)
quantile(poids_femme,0.25)
quantile(poids_femme,0.75)

# 2. Représenter graphiquement ces 2 groupes.
boxplot(depression_long$poids~depression_long$sexe)

# 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.

##### Hommes

## IC hommes n> 30 pas de condition

### IC à 95%

CI(poids_homme,0.95)

### IC à 98%
CI(poids_homme,0.98)

##### Femmes

## IC femmes n< 30 condition

shapiro.test(poids_femme)

## => on ne peut pas calculer les IC

```

84

16

87.6309523809524

86

8.29541862514363

25\%: 81.75

75\%: 92

71.0625

72

3.25512416557853

25\%: 69.25

75\%: 74

inf 85.8307361812191 sup

89.4311685806856


inf 85.483937437681 sup

89.7779673242238

Shapiro-Wilk normality test

data: poids_femme

W = 0.81692, p-value = 0.00461



En utilisant ce nouveau tableau, pour le poids des 2 groupes d'urbanisation :

1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.
2. Représenter graphiquement ces 2 groupes.
3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.
4. Qu'en concluez-vous ?

[26]: *# 1. Calculer la moyenne, la médiane, l'écart type et les quartiles de ces 2 groupes.*

```
poids_A=depression_long$poids[depression_long$urbanisation=="A"]
poids_B=depression_long$poids[depression_long$urbanisation=="B"]
```

```
length(poids_B)
```

```

length(poids_A)

# Statistique concernant les A
mean(poids_A)
median(poids_A)
sd(poids_A)
quantile(poids_A,0.25)
quantile(poids_A,0.75)

# Statistique concernant les B
mean(poids_B)
median(poids_B)
sd(poids_B)
quantile(poids_B,0.25)
quantile(poids_B,0.75)

# 2. Représenter graphiquement ces 2 groupes.
boxplot(depression_long$poids[depression_long$urbanisation!=
  ↪="C"]~depression_long$urbanisation[depression_long$urbanisation!="C"])

# 3. calculez l'intervalle de confiance de ces 2 groupes à 95% et 98%.

##### Hommes

## IC A n> 30 pas de condition

### IC à 95%

CI(poids_A,0.95)

### IC à 98%
CI(poids_A,0.98)

##### B

## IC femmes n > 30 pas de condition

### IC à 95%

CI(poids_B,0.95)

### IC à 98%
CI(poids_B,0.98)

# 4. Qu'en concluez-vous ?

```

48

85.4166666666667

83.5

9.84525662510553

25\%: 79

75\%: 92

84.5106382978723

85

9.53226178832233

25\%: 77


75\%: 91

inf	82.5579021410765 sup	88.2754311922569
------------	-----------------------------	------------------

inf	81.9943110752769 sup	88.8390222580565
------------	-----------------------------	------------------

inf	81.7118613874458 sup	87.3094152082989
------------	-----------------------------	------------------

inf	81.1594566483847 sup	87.86181994736
------------	-----------------------------	----------------



Exercice E

1. Représenter graphiquement les boxplots représentant pour les groupes 1 et 2 :

- a) les scores de Hamilton en séparant les hommes et les femmes.
- b) les âges en séparant les hommes et les femmes.
- c) les poids en séparant les hommes et les femmes.

sur un seul graphique

```
[27]: head(depression_long)

# a) les scores de Hamilton en séparant les hommes et les femmes.
```

```

boxplot(depression_long$hamilton~depression_long$groupe+depression_long$sexe)

# b) les âges en séparant les hommes et les femmes.

boxplot(depression_long$age~depression_long$groupe+depression_long$sexe)


# c) les poids en séparant les hommes et les femmes.


boxplot(depression_long$poids~depression_long$groupe+depression_long$sexe)


```

A data.frame: 6 × 6

		groupe	hamilton	urbanisation	age	poids	sexe
		<chr>	<int>	<chr>	<int>	<int>	<chr>
1		G1	43	B	57	74	F
2		G2	25	B	48	93	H
3		G1	29	A	37	95	H
4		G2	29	B	41	92	H
5		G1	34	A	7	84	H
6		G2	18	A	30	86	H







2. Représenter graphiquement le score Hamilton en fonction de l'âge pour les 2 groupes. Vous devez utiliser la fonction `plot()` qui permet de représenter un nuage de point et prend comme deux premiers arguments les données de l'axe des abscisses et celles de l'axe des ordonnées. Vous pouvez leur donner une couleur différente avec l'argument `col=`.

sur un seul graphique (je vous conseille d'utiliser le tableau `depression_long`)

```
[28]: zfac <- factor(depression_long$groupe)

mescouleurs <- rainbow(length(levels(zfac)))

plot(depression_long$age,depression_long$hamilton,col = mescouleurs[zfac],pch = 19)
```

