

TD5_Comparaison_2_moyennes_indépendantes

August 25, 2026

1 TD 5 : Test de comparaison de deux moyennes de deux échantillons indépendants

Christelle Gonindard, Matthais Grenié, François Bettega

1.1 Objectifs

- Faire la différence entre un test bilatéral et un test unilatéral
- Connaître les conditions d'application d'un test de comparaison de moyennes entre deux échantillons indépendants
- Apprendre à mettre en œuvre un test de Student pour comparer une moyennes entre deux échantillons indépendants
- Interpréter le résultat de ce test

1.2 1. Présentation des données

Un clinicien évalue l'intensité de la dépression sur l'échelle de Hamilton qui varie de 0 (non déprimé) à 56 (très déprimé), chez 100 patients souffrant d'un Episode Dépressif Majeur (EDM). On veut savoir si l'acupuncture améliore l'évolution de la dépression. Pour cela, 100 malades de même état dépressif (même score de Hamilton) sont répartis en 2 groupes de 50 par tirage au sort. Le groupe I a reçu uniquement le traitement pharmacologique et le groupe II a reçu le traitement pharmacologique associé à de l'acupuncture.

Le jeu de données contient les variables suivantes en colonne : - **hamilton_g1** : Les scores de Hamilton, après 8 mois de traitement pour le groupe 1 ; - **hamilton_g2** : Les scores de Hamilton, après 8 mois de traitement pour le groupe 2 ; - **age_g1** : l'âge des patients du groupe 1 ; - **age_g2** : l'âge des patients du groupe 2 ; - **poids_g1** : le poids des patients du groupe 1 ; - **poids_g2** : le poids des patients du groupe 2 ; - **sexe_g1** : le sexe des patients du groupe 1 ("F" : femme, "H" : homme) ; - **sexe_g2** : le sexe des patients du groupe 2 ("F" : femme, "H" : homme) ; - **urbanisation_g1** : le niveau d'urbanisation dans lequel vivent les patients du groupe 1 ("A" : rural, "B" : urbanisation modéré, "C" : fortement urbanisé) ; - **urbanisation_g2** : le niveau d'urbanisation dans lequel vivent les patients du groupe 2 ("A" : rural, "B" : urbanisation modéré, "C" : fortement urbanisé).

Les données sont contenues dans le fichier texte nommé **depression.txt** qui se trouve dans le dossier **data**. Le chemin d'accès complet du fichier est donc **data/depression.txt**.

```
[1]: depression <- read.table("data/depression.txt", header = TRUE)
```

```
# Afficher le début du contenu du fichier de données
head(depression)

CI <- function(x, confidence){
  alpha = 1 - confidence
  mu = mean(x)
  sigma = sd(x)
  n = length(x)
  CI_inf = mu - (qt(1 - alpha/2, n-1) * sigma/sqrt(n))
  CI_sup = mu + (qt(1 - alpha/2, n-1) * sigma/sqrt(n))
  CI = c(inf = CI_inf, sup = CI_sup)
  return(CI)
}
```

		hamilton_g1	hamilton_g2	urbanisation_g1	urbanisation_g2	age_g1	age_g2
		<int>	<int>	<chr>	<chr>	<int>	<int>
A data.frame: 6 × 10	1	43	25	B	B	57	48
	2	29	29	A	B	37	41
	3	34	18	A	A	7	30
	4	39	23	A	A	37	41
	5	40	24	B	A	15	30
	6	41	25	B	B	45	45

Objectif de la séance: On aimerait savoir si l'acupuncture améliore l'évolution de la dépression en plus d'un traitement pharmacologique chez les femmes en comparant le groupe 1 et le groupe 2

1.3 2. Principe

Ici, on cherche à comparer les moyennes de deux échantillons indépendants (= il n'y a pas de liens entre les femmes assignées aux deux groupes). Pour cela, on doit réaliser un test de Student de comparaison de deux échantillons indépendants.

Le principe du test est analogue à celui de comparaison à une moyenne théorique, seulement, ici, le test va calculer la différence entre les deux moyennes observées. Si l'écart est suffisamment éloigné de 0 avec un certain risque d'erreur α alors on conclura que les deux moyennes sont différentes.

Le test calcule la statistique t en faisant la différence entre μ_1 moyenne du groupe 1 et μ_2 moyenne du groupe 2 et en divisant par leurs écart-types S_1 et S_2 , respectivement :

$$t = \frac{\mu_1 - \mu_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

avec n_1 la taille du premier échantillon et n_2 la taille du second échantillon (ils n'ont pas forcément la même taille).

1.4 3. Description des données

Avant de commencer une analyse il est important de présenter et vérifier les données : - Extraire les deux échantillons - Calculer leurs tailles - Faire un résumé statistique de chacun des échantillons

```
[2]: # Extraction des deux échantillons
femme_g1 <- depression$hamilton_g1[depression$sexe_g1 == "F"]
femme_g2 <- depression$hamilton_g2[depression$sexe_g2 == "F"]

# Taille de l'échantillon
length(femme_g1)
length(femme_g2)

# Résumé statistique
summary(femme_g1)
summary(femme_g2)
```

11

5

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
37.00	39.00	42.00	41.64	43.50	47.00

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
18.0	23.0	24.0	24.8	26.0	33.0

Conclusion :

- les échantillons sont de petites tailles : 11 patientes pour le groupes 1 et 5 pour le groupes 2
- il semblerait que les femmes du groupes 1 aient un niveau dépressif plus élevé que les femmes du groupes 2 avec des moyennes respectives de 41.64 et 24.8 et des médianes respectives de 42 et 24. il apparait également que le troisième quartile du groupe 2 représentant 75% des patientes (26) soit inférieur au premier quartile du groupe 1 (39), ce qui va dans le sens d'une différence importante observée entre les deux groupes

Au vu de ces résultats, il serait intéressant de tester l'hypothèse suivante : le niveau de dépression dans le groupe 2 est inférieur au niveau de dépression dans le groupe 1 ce qui impliquerait une efficacité de l'association traitement + acupuncture dans le traitement de la dépression.

1.5 4. Conditions d'application

Pour utiliser le test de Student de comparaison de deux échantillons indépendants, il faut vérifier les conditions d'application suivantes : - Si la taille **des deux échantillons** est grande ($n_1 \geq 30$ et $n_2 \geq 30$) : on peut directement procéder au test, - Si la taille d'**au moins un des échantillons** est inférieure à 30 ($n_1 < 30$ ou $n_2 < 30$), alors il faut que : - les données des deux échantillons suivent une loi normale - les variances des deux échantillons soient égales

Comme nos échantillons ont respectivement 11 et 5 observations, il va falloir vérifier les autres conditions d'application.

1.5.1 4.1 Normalité des données

Pour vérifier que la distribution de nos échantillons suit une loi Normale on va appliquer le test de Shapiro sur chacun des deux échantillons. Pour vérifier nos résultats on réalisera aussi les diagrammes quantile-quantile des deux échantillons.

Rappel des hypothèses du test de Shapiro

H0 : la distribution suit une loi normale

H1 : la distribution ne suit pas une loi normale

Réalisez les tests de Shapiro puis interprétez-les

```
[3]: shapiro.test(femme_g1)
      shapiro.test(femme_g2)
```

Shapiro-Wilk normality test

```
data:  femme_g1
W = 0.94764, p-value = 0.614
```

Shapiro-Wilk normality test

```
data:  femme_g2
W = 0.96258, p-value = 0.8258
```

Conclusion :


On observe dans les deux cas $p > \alpha = 0.05$, on ne peut pas rejeter l'hypothèse H0 donc la distribution des scores de Hamilton des femmes dans les groupes 1 et 2 suit une loi normale.


Nous allons le confirmer avec les diagrammes quantiles-quantiles

```
[4]: qqnorm(femme_g1)
      qqline(femme_g1)

      qqnorm(femme_g2)
      qqline(femme_g2)
```

Normal Q-Q Plot





Les quantiles des femmes du groupe 1 s'alignent bien avec les quantiles théoriques d'une loi normale, en revanche, pour le groupe 2 c'est plus compliqué à vérifier du fait du faible échantillonnage (seulement 5 patientes). On remarque des difficultés d'ajustement aux niveaux des extrémités, ceci est probablement dû à la petite taille du jeu de données.

1.5.2 4.2 Égalité des variances = test de Fisher

Principe du test On va vérifier l'égalité des variances entre les échantillons par le [test de Fisher-Snedecor](#). Ce test calcule une statistique appelée F (comme Fisher) qui est le rapport entre la plus grande sur la plus petite des variances des deux échantillons. Si ce rapport est suffisamment supérieur à 1 avec un certain risque d'erreur α alors on considère les variances comme différentes

$$F = \frac{\sigma_{\max}^2}{\sigma_{\min}^2}$$

avec $\sigma_{\max}^2$ la variance de l'échantillon ayant la plus grande variance et $\sigma_{\min}^2$ celle de celui avec la plus petite variance.

Hypothèses du test Les hypothèses du test de Fisher sont les suivantes :

H0 : Les variances sont égales dans les deux échantillons

H1 : Les variances sont différentes entre les deux échantillons

Il n'y a pas de condition d'application à vérifier pour réaliser le test.

Réalisation Pour réaliser le test sur R, il faut utiliser la fonction `var.test()` (pour *variance test* en anglais), cette fonction prend comme deux premiers arguments les deux échantillons à comparer.

Réalisez le test avec les deux groupes

```
[5]: var.test(femme_g1, femme_g2)
```

```
F test to compare two variances
```

```
data: femme_g1 and femme_g2
```

```
F = 0.39241, num df = 10, denom df = 4, p-value = 0.2099
```

```
alternative hypothesis: true ratio of variances is not equal to 1
```

```
95 percent confidence interval:
```

```
0.04437067 1.75341717
```

```
sample estimates:
```

```
ratio of variances
```

```
0.3924089
```

Conclusion :

Au seuil 5%, $p = 0,2099$, on ne peut pas rejeter H0 quelque soit la valeur de α .

Toutes les conditions d'application sont donc validées pour réaliser le test de Student de comparaison de deux moyennes indépendantes.

1.6 5. Réalisation du test de Student

De la même façon que pour le test de comparaison à une moyenne théorique, le test peut s'effectuer de manière bilatérale ou unilatérale. Ici, comme on veut savoir si les femmes du groupe 1 (qui n'ont pas eu d'acupuncture) ont des scores de dépression plus élevés que celles du groupe 2 (qui ont été traitées par de l'acupuncture), on va plutôt réaliser un test unilatéral, il faudra donc spécifier l'argument `alternative = "greater"`.

Les hypothèses de notre test sont donc :

H0 : Les moyennes sont égales dans les deux groupes.

H1 : la moyenne du score de Hamilton du groupe 1 est supérieure à la moyenne du score de Hamilton du groupe 2.

Pour réaliser le test, on va à nouveau utiliser la fonction `t.test()` qui prend comme deux premiers arguments les deux échantillons, puis on spécifiera l'argument `alternative=`, enfin, étant donné qu'on a vérifié l'égalité des variances entre les échantillons on va spécifier l'argument logique `var.equal = TRUE`.

```
[6]: t.test(femme_g1, femme_g2, alternative = "greater", var.equal = TRUE)
```

Two Sample t-test

```
data: femme_g1 and femme_g2
t = 7.6134, df = 14, p-value = 1.213e-06
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 12.9414      Inf
sample estimates:
mean of x mean of y
 41.63636  24.80000
```

Conclusion :

On observe $p = < \alpha = 0.05$, on rejette l'hypothèse H0 donc le score de Hamilton du groupe 1 est supérieur au score de Hamilton du groupe 2. L'association traitement + acupuncture est donc plus efficace que le traitement seul.

Note : ici on a spécifié l'argument `var.equal = TRUE` (vrai) il peut prendre aussi la valeur `FALSE` (faux), cela signifierait que les variances des deux échantillons ne sont pas égales, dans ce cas-là c'est un autre test statistique qui est réalisé est le [test de Welch](#), c'est une adaptation du test de Student quand les variances ne sont pas égales

1.7 En résumé

Dans cette séance :

- Nous avons appris à effectuer un test de Student avec la fonction `t.test()`, en précisant deux arguments pour préciser les deux échantillons indépendants
- Nous avons appris les conditions d'application des tests de Student de comparaison de deux échantillons indépendants :
 - si $n_1 \geq 30$ et $n_2 \geq 30$, on peut directement procéder au test
 - si $n_1 < 30$ **ou** $n_2 < 30$ (ou bien les deux !), alors il faut :
 1. que les **deux échantillons** suivent une loi normale
 2. que les variances des deux échantillons soient égales
- Quand les variances sont égales, on précise `var.equal = TRUE` en argument de la fonction `t.test()`
- On peut aussi réaliser des tests unilatéraux quand on compare deux échantillons indépendants

1.8 6. Exercices

1.8.1 Exercice d'application

Exercice 1 L'activité diurétique d'un nouveau médicament et celle d'un produit X d'activité diurétique connue sont comparées chez la souris. Vingt souris de même âge sont réparties en deux groupes de 10. Un groupe reçoit le nouveau médicament et l'autre groupe reçoit le produit X.

- **Question 1.** Parmi les trois méthodes indiquées ci-dessous, quelle est la méthode la plus appropriée pour constituer les deux groupes ? Justifier votre réponse.
 1. 1ère méthode : les 20 souris sont réparties par tirage au sort en 2 groupes de 10 souris.
 2. 2ème méthode : les 20 souris sont toutes placées dans une même cage, l'expérimentateur attrape les 10 premières souris qui se présentent à la sortie de la cage et les place dans une autre cage.
 3. 3ème méthode : toutes les souris sont pesées afin de constituer 2 groupes de poids le plus homogène possible. Ainsi, un groupe est constitué des 10 souris de poids le plus faible ; l'autre est constitué des 10 souris de poids le plus élevé.
- **Question 2.** Deux conceptions de protocole peuvent être envisagées. Le traitement connu peut être un placebo ou un traitement diurétique de référence. Discuter le choix de chacune de ces deux stratégies.
- **Question 3.** Une dose fixe de 20 mg du nouveau médicament ou du produit X est administrée à chaque animal. Les deux groupes de 10 souris sont placés dans des cages à métabolisme qui permettent une mesure facile du volume urinaire.
Les résultats sont contenus dans le fichier `exercice1_TD3.txt` qui est dans le dossier `data/` avec le chemin d'accès complet `data/exercice1_TD3.txt`.
La diurèse observée avec le nouveau médicament est-elle significativement supérieure à celle observée avec le produit X, au risque $\alpha = 5\%$, et au risque $\alpha = 1\%$?

Question 1

La méthode 1 est préférable car elle répartie aléatoirement les souris dans les 2 groupes ce qui évite tout biais comme par exemple avec la méthode 3 qui a un biais de poids et la méthode 1 un biais d'agilité.

Question 2

- Le traitement connu peut être comparé à un placebo => Montre l'efficacité du traitement
- Le traitement connu peut être comparé à un traitement diurétique de référence => Montre que le nouveau traitement est plus efficace que le traitement de référence par exemple

Question 3 La diurèse observée avec le nouveau médicament est-elle significativement supérieure à celle observée avec le produit X, au risque 5%, au risque 1% ?

Test de comparaison de deux échantillons indépendants

```
[7]: # Lecture des données
insurance = read.table("data/exercice1_TD3.txt",h=T)

head(insurance)

# description des données
```

```

summary(insurance$produit_x)
summary(insurance$nouveau_medicament)
dim(data)

# Effectif inférieur à 30 => vérification des condition d'application
shapiro.test(insurance$produit_x)
shapiro.test(insurance$nouveau_medicament)
var.test(insurance$nouveau_medicament,insurance$produit_x)

# H0 La diurèse observée avec le nouveau médicament est
# égale à celle observée avec le produit X
# H1 La diurèse observée avec le nouveau médicament
# est supérieure à celle observée avec le produit X

t.test(insurance$nouveau_medicament,insurance$produit_x,alternative="greater"
      ,var.equal = T)

```

A data.frame: 6 × 2

	produit_x <dbl>	nouveau_medicament <dbl>
1	17.09903	23.54705
2	16.06864	23.40862
3	12.25383	23.55035
4	14.09870	17.86841
5	20.10046	21.40830
6	16.25313	16.51751

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
12.25	16.11	17.20	17.96	20.03	23.78

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
16.52	18.34	21.26	20.86	23.51	23.72

NULL

Shapiro-Wilk normality test

data: insurance\$produit_x
W = 0.96599, p-value = 0.8514

Shapiro-Wilk normality test

data: insurance\$nouveau_medicament
W = 0.87496, p-value = 0.1141

F test to compare two variances

```
data: insurance$nouveau_medicament and insurance$produit_x
F = 0.56138, num df = 9, denom df = 9, p-value = 0.4027
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.139439 2.260115
sample estimates:
ratio of variances
 0.5613806
```

Two Sample t-test

```
data: insurance$nouveau_medicament and insurance$produit_x
t = 2.0101, df = 18, p-value = 0.02982
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 0.3989522      Inf
sample estimates:
mean of x mean of y
20.86216 17.95739
```

1.8.2 Exercices supplémentaires

Exercice 2 Pour cet exercice nous allons travailler un jeu de données contenant le nombre de morts par an par pays en fonction des différentes causes de mort sur plusieurs années. Le fichier s'intitule `annual_number_of_deaths_by_cause.txt` et est situé dans le dossier `data/` avec le chemin d'accès complet `data/annual_number_of_deaths_by_cause.txt`.

1. Charger le jeu de données et décrivez le brièvement

```
[8]: deaths = read.table("data/annual_number_of_deaths_by_cause.txt", header = TRUE)

head(deaths)
```

A data.frame: 6 × 36

	Entity	Code	Year	Number.of.executions	Meningitis.	Alzheimer.s.disea
	<chr>	<chr>	<int>	<int>	<int>	<int>
1	Afghanistan	AFG	2007	15	2933	1402
2	Afghanistan	AFG	2008	17	2731	1424
3	Afghanistan	AFG	2009	0	2460	1449
4	Afghanistan	AFG	2011	2	2327	1508
5	Afghanistan	AFG	2012	14	2254	1544
6	Afghanistan	AFG	2013	2	2281	1581

2. Quelles sont les pays où il y a eu au moins une exécution ?
(indice : vous pouvez utiliser la fonction `table()` pour éviter d'afficher les pays où c'est arrivé plusieurs années).

```
[9]: table(deaths$Entity[deaths$Number.of.executions >= 1])
```

Afghanistan	Bahrain	Bangladesh
8	2	9
Belarus	Botswana	Chad
7	7	1
China	Egypt	Equatorial_Guinea
1	7	3
Ethiopia	Gambia	India
1	1	3
Indonesia	Iran	Iraq
5	10	10
Japan	Jordan	Kuwait
9	2	2
Libya	Malaysia	Mongolia
4	5	1
Nigeria	North_Korea	Oman
2	4	2
Pakistan	Palestine	Saudi_Arabia
6	6	10
Singapore	Somalia	South_Sudan
6	8	4
Sudan	Syria	Taiwan
10	4	7
Thailand	United_Arab_Emirates	United_States
1	5	10
Vietnam	World_(excluding_China)	Yemen
5	10	9

3. Quelles sont les années où il y a eu au moins une exécution ?
(indice : vous pouvez à nouveau utiliser la fonction `table()`)

```
[10]: table(deaths$Year[deaths$Number.of.executions >= 1])
```

```
2007 2008 2009 2010 2011 2012 2013 2014 2015 2016
23   24   17   21   18   21   20   21   22   20
```

4. Représentez le nombre de noyades (Drowning.) aux Barbades ("Barbados") chaque année.

```
[11]: x
x = deaths$Drowning.[deaths$Entity == "Barbados"]
length(x)
boxplot(x, main = "Nombre de Noyades aux Barbades")
```

```
Error in eval(expr, envir, enclos): objet 'x' introuvable
Traceback:
```

5. Quelles sont la variance, la moyenne, l'intervalle de confiance à 98% de la moyenne, la médiane, et le premier et dernier décile du nombre de décès par hépatite aiguë (*Acute.hepatitis.*) au Kirghizistan (*Kyrgyzstan*) depuis 2004 ?

Remarque : Vous observerez certainement des données manquantes sur NA (pour *Not Available* en anglais). R permet de garder une trace explicite de ces données. Si vos données en contiennent, vous pouvez les enlever avec la fonction de `na.omit()` en réassignant vos données par exemple `x_no_na : x_no_na = na.omit(x)`

Rappel : pour calculer des quantiles différents des quartiles, vous pouvez utiliser la fonction `quantile()` qui prend comme premier argument l'échantillon et en deuxième argument le nombre inférieur ou égal à 1 qui correspond au quantile à calculer.

```
[ ]: # Compute year number fifteen years ago
x = deaths$Acute.hepatitis.[deaths$Year >= 2004 & deaths$Entity == "Kyrgyzstan"]

summary(x)

# Remove NAs
xx=na.omit(x)

var(xx)
mean(xx)
CI(xx,0.98)
median(xx)
quantile(xx,0.1)
quantile(xx,0.9)
```

- 6.Même question pour les années avant 2011 au Koweït (*Kuwait*).

```
[ ]: x = deaths$Acute.hepatitis.[deaths$Year <= 2010]
summary(x)
xx=na.omit(x)
var(xx)
mean(xx)
CI(xx,0.98)
median(xx)
quantile(xx,0.1)
quantile(xx,0.9)
```

7. Dans quel pays et en quelles années se trouvent le nombre minimum de morts par malnutrition (*Nutritional.deficiencies.*).

```
[ ]: summary(deaths$Nutritional.deficiencies.)

# Calcul du nombre minimum de morts par malnutrition
m = min(na.omit(deaths$Nutritional.deficiencies.))
m

# Pays
x=deaths$Entity[deaths$Nutritional.deficiencies.==m]
table(x)
xx=na.omit(x)
unique(xx)

# Années
y=deaths$Year[deaths$Nutritional.deficiencies.==m]
yy=na.omit(y)
unique(yy)
```

8. Tester au seuil à $\alpha = 0.98$, si la moyenne du nombre de morts par le paludisme (Malaria) en Inde ("India") est inférieur à 79713.

```
[ ]: # Test de comparaison à une moyenne théorique
# H0 m = mu
# H1 m < mu

x=deaths$Malaria.[deaths$Entity=="India"]

# n=30 => Student
length(x)

t.test(x, mu = 79713, alternative = "less")

#Conclusion au seuil 2%, on ne peut pas rejeter H0
```

9. Tester, au seuil $\alpha = 1\%$, si le nombre de morts par méningite (Meningitis.) au Mexique ("Mexico") est différent de sa moyenne moins une fois et demie son écart type.

```
[ ]: # créer le groupe
x=deaths$Meningitis.[deaths$Entity=="Mexico"]

#Description
summary(x)

# n = 30 = test de Student
n=length(x)
n

# Calcul de mu
```

```
xecart = mean(x)-1.5*sd(x)/sqrt(n)

# Student
t.test(x, mu = xecart)

# au seuil 1%, pas de différence significative
```

10. Même question, mais cette fois la moyenne moins 3 fois sont écart type

```
[ ]: # créer le groupe
x=deaths$Meningitis.[deaths$Entity=="Mexico"]

#Description
summary(x)

# n = 30 = test de Student
n=length(x)
n

# Calcul de mu
xecart=mean(x)-1.5*sd(x)/sqrt(n)

# Student
t.test(x,mu=xecart)

# au seuil 1%, différence significative
```

Exercice 3 En utilisant le jeu de données de l'exercice précédent répondez aux questions suivantes.

1. Tester au seuil $\alpha = 0.02\%$ si le nombre de morts par la tuberculose (Tuberculosis.) en Argentine ("Argentina") est différent de celui en France.

```
[ ]: # Créer les groupes

A=deaths$Tuberculosis.[deaths$Entity=="Argentina"]
F=deaths$Tuberculosis.[deaths$Entity=="France"]

# Description
summary(A)
summary(F)
length(A)
length(F)

# NA et NF = 30 => Student pour données indépendantes

# H0 : pas de différence du nombre de morts entre les deux pays
# H1 : différence du nombre de morts entre les deux pays
```

```
t.test(A,F)
```

```
# Au seuil 2%, pvalue < 0.02, on rejète H0, il existe  
# bien une différence significative du le nombre de morts par tuberculose  
# entre l'Argentine et la France
```

2. Calculer les 2 intervalles de confiance, au niveau de confiance 0.99, de ces moyennes, concluez.

```
[ ]: CI(A,0.99)  
      CI(F,0.99)
```

3. Tester si la moyenne du nombre de morts par maladie cardiovasculaire (Cardiovascular.diseases.) est différente entre l'Irlande ("Ireland") et l'Angleterre ("England"), au seuil $\alpha = 4\%$.

```
[ ]: # Créer les groupes  
  
I=deaths$Cardiovascular.diseases.[deaths$Entity=="Ireland"]  
E=deaths$Cardiovascular.diseases.[deaths$Entity=="England"]  
  
# Description  
summary(I)  
summary(E)  
length(I)  
length(E)  
  
# NA et NF = 30 => Student pour données indépendantes  
  
# H0 : pas de différence du nombre de morts entre les deux pays  
# H1 : différence du nombre de morts entre les deux pays  
  
t.test(I,E)  
  
# Au seuil 4%, pvalue < 0.04, on rejète H0, il existe  
# bien une différence significative du le nombre de morts par maladies  
# Cardiaques est significativement différent entre l'Angleterre et  
# l'Irlande
```

6. Tester si la moyenne du nombre de morts par maladie cirrhose (Cirrhosis.and.other.chronic.liver.diseases.) est différente entre la France et l'Égypte ("Egypt"), au seuil $\alpha = 1\%$.

```
[ ]: # Créer les groupes  
  
E=deaths$Cirrhosis.and.other.chronic.liver.diseases.[deaths$Entity=="Egypt"]  
F=deaths$Cirrhosis.and.other.chronic.liver.diseases.[deaths$Entity=="France"]  
  
# Description
```

```
summary(F)
summary(E)
length(F)
length(E)

# NA et NF = 30 => Student pour données indépendantes

# H0 : pas de différence du nombre de morts entre les deux pays
# H1 : différence du nombre de morts entre les deux pays

t.test(F,E)

# Au seuil 1%, pvalue < 0.01, on rejète H0, il existe
# bien une différence significative du nombre de morts par
# maladie cirrhose est différente entre la France et l'Égypte
```

7. Tester si la moyenne du nombre de morts liés au trouble maternel (`Maternal.disorders.`) en Italie ("Italy") est inférieure à celui du Botswana ("Botswana"), au seuil $\alpha 3\%$.

```
[ ]: # Créer les groupes

B=deaths$Maternal.disorders.[deaths$Entity=="Botswana"]
I=deaths$Maternal.disorders.[deaths$Entity=="Italy"]

# Description
summary(B)
summary(I)
length(B)
length(I)

# NA et NF = 30 => Student pour données indépendantes

# H0 : pas de différence du nombre de morts entre les deux pays
# H1 : nb mort Italy < nb mort Botswana

t.test(I, B, alternative = "less")

# Au seuil 3%, pvalue < 0.03, on rejète H0, il existe
# nombre de morts liés au trouble maternel
# en Italie est significativement inférieure à celui du Botswana
```

Exercice 4 Nous allons utiliser le jeu de données `insurance.txt` déjà utilisé dans le TD 3

Rappel des données :

Le fichier de données `insurance.txt`, que nous allons analyser, est constitué des données clients suivantes:

- `age` : âge du principal bénéficiaire

- **sex** : sexe de l'assureur, féminin, masculin
- **bmi** : indice de masse corporelle (*body mass index* en anglais), permettant de comprendre le corps, les poids relativement élevés ou faibles par rapport à la taille, indice objectif du poids corporel (kg/m^2) utilisant le rapport taille/poids, idéalement 18,5 à 24,9
- **children** : Nombre d'enfants couverts par l'assurance maladie / Nombre de personnes à charge
- **smoker** : fumeur ("yes") ou non (no)
- **region** : zone de résidence du bénéficiaire aux États-Unis ("northeast" = Nord-Est ; "northwest" = Nord-Ouest ; "southeast" = Sud-Est ; "southwest" = Sud-Ouest)
- **charges** : Frais médicaux individuels facturés par l'assurance maladie

1. Charger le jeu de données `insurance.txt` qui se trouve dans le dossier `data/` soit le chemin d'accès `data/insurance.txt`

```
[ ]: data=read.table("data/insurance.txt",h=T)

head(data)
```

2. Soit la variable `bmi`, calculer sa moyenne, sa variance, ainsi que son écart interquartile et l'intervalle de confiance de sa moyenne au niveau de confiance 0.98 pour les femmes entre 25 et 45 ans compris.

```
[ ]: C.I <- function(x,alpha){
  alpha <- 1-alpha
  mu = mean(x)
  sigma <- sd(x)
  n = length(x)
  CI_inf = mu - (qt(1 - alpha/2,n-1) * sigma/sqrt(n))
  CI_sup = mu + (qt(1 - alpha/2,n-1) * sigma/sqrt(n))
  CI = c(inf = CI_inf ,sup = CI_sup)
  return(CI)
}
```

```
[ ]: # créer le groupe de données
x=insurance$bmi[insurance$sex=="female" & insurance$age >= 25 & insurance$age_
  ↪ <= 45 ]

length(x)

mean(x)
var(x)
quantile(x,0.75)-quantile(x,0.25)

# n > 30 donc on peut calculer l'IC
C.I(x,0.98)
```

3. Calculer les effectifs croisés entre les régions et le sexe
(il faut utiliser la fonction `table()` en précisant les deux variables comme deux premiers

arguments de la fonction)

```
[ ]: table(insurance$region,insurance$sex)
```

4. Calculer les effectifs croisés entre les individus ayant 3 enfants ou plus et la région d'habitation.

```
[ ]: table(insurance$children[insurance$children>=3],  
↳ insurance$region[insurance$children>=3])
```

5. Tester au seuil de $\alpha = 2\%$ si les charges d'assurance des hommes sont supérieures en moyenne à celle des femmes.

```
[ ]: # Test de comparaison de deux échantillons indépendants  
  
# Groupes  
H=insurance$charges[insurance$sex=="male"]  
F=insurance$charges[insurance$sex=="female"]  
  
# description  
length(F)  
length(H)  
  
summary(H)  
summary(F)  
  
# H0 : les charges d'assurances sont égales entre les hommes et  
# les femmes  
# H1 : les charges d'assurances sont supérieures pour les hommes  
# par rapport aux femmes  
  
t.test(H,F,alternative="greater")  
  
# Conclusion : au seuil 2%, pvalue < 0.01 donc on rejète H0  
# les charges d'assurances sont significativement supérieures  
# pour les hommes  
# par rapport aux femmes
```

6. Calculer l'intervalle de confiance de la moyenne des charges d'assurance des hommes et celui des femmes au niveau de confiance 98% et concluez

```
[ ]: # les effectifs sont >= 30 donc pas de condition d'application  
C.I(H,0.98)  
C.I(F,0.98)
```

7. Tester si les charges d'assurance des habitants du Northwest sont différentes en moyenne de celle des habitants du Southwest, au seuil $\alpha = 5\%$.

```
[ ]: # Test de comparaison de deux échantillons indépendants  
  
# Groupes
```

```

N=insurance$charges[insurance$region=="northwest"]
S=insurance$charges[insurance$region=="southwest"]

# description
length(N)
length(S)

summary(N)
summary(S)

# H0 : les charges d'assurances sont égales entre le nord et le sud
# les femmes
# H1 : les charges d'assurances sont différentes entre el nord et le sud

t.test(N,S)

# Conclusion : au seuil 5%, pvalue > 0.05 donc on ne peut pas rejeter H0
# il n'y a pas de différence significative au niveau des charges entre N et S

```

8. Tester si les hommes fumeurs sont plus jeunes en moyenne que les non-fumeurs, au seuil $\alpha = 3\%$.

```

[ ]: # Test de comparaison de deux échantillons indépendants

# Groupes
F=insurance$age[insurance$smoker=="yes" & insurance$sex=="male"]
NF=insurance$age[insurance$smoker=="no" & insurance$sex=="male"]

# description
length(F)
length(NF)

summary(NF)
summary(F)

# H0 : les hommes fumeurs et non fumeur ont en moyenne le même âge
# H1 : les fumeurs sont plus jeunes que les non fumeurs

t.test(F,NF,alternative="less")

# Conclusion : au seuil 3%, pvalue > 0.03 donc on ne peut pas rejeter
# H0
# les fumeurs ne sont pas significativement plus jeunes que les non fumeurs

```

9. Calculer l'intervalle de confiance de la moyenne de l'âge des hommes chez les fumeur puis chez les non fumeur au niveau de confiance 0.97, concluez.

```
[ ]: # description
length(F)
length(NF)
# pas de condition car effectif >=30

C.I(F,0.97)
C.I(NF,0.97)
```

10. Tester si les femmes fumeuses sont plus âgées en moyenne que les non-fumeuses, au seuil $\alpha = 3\%$.

```
[ ]: # Test de comparaison de deux échantillons indépendants

# Groupes
F=insurance$age[insurance$smoker=="yes" & insurance$sex=="female"]
NF=insurance$age[insurance$smoker=="no" & insurance$sex=="female"]

# description
length(F)
length(NF)

summary(NF)
summary(F)

# H0 : les femmes fumeuses et non fumeuses ont en moyenne le même âge
# H1 : chez les femmes, les fumeurs sont plus âgées que les non fumeurs

t.test(F,NF,alternative="greater")

# Conclusion : au seuil 3%, pvalue > 0.03 donc on ne peut pas rejeter
# H0
# les femmes fumeuses et non fumeuses ont en moyenne le même âge
```

11. Calculer l'intervalle de confiance de la moyenne de l'âge des femmes chez les fumeuses puis chez les non fumeuses au niveau de confiance 0.97, concluez.

```
[ ]: C.I(NF,0.97)
C.I(F,0.97)
```